DETECCIÓN DE RETINOPATÍA DIABÉTICA EN IMÁGENES DEL FONDO DEL OJO UTILIZANDO ALGORITMOS DE APRENDIZAJE PROFUNDO

CAMILO ERNESTO SERRANO LOZADA
OSCAR MAURICIO CAMPOS SEPULVEDA

UNIVERSIDAD INDUSTRIAL DE SANTANDER
FACULTAD DE INGENIERÍAS FISICOMECÁNICAS
ESCUELA DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
BUCARAMANGA
2026

DETECCIÓN DE RETINOPATÍA DIABÉTICA EN IMÁGENES DEL FONDO DEL OJO UTILIZANDO ALGORITMOS DE APRENDIZAJE PROFUNDO

Trabajo de Grado para optar al título de
Ingeniero de Sistemas

Director:
Jorge Villamizar Morales
Doctor en Ciencias Aplicadas

Codirector:
Lola Xiomara Bautista Rozo
Ph.D. en Automatización, tratamiento de señales e imágenes

UNIVERSIDAD INDUSTRIAL DE SANTANDER
FACULTAD DE INGENIERÍAS FISICOMECÁNICAS
ESCUELA DE INGENIERÍA DE SISTEMAS E INFORMÁTICA
BUCARAMANGA
2026

DEDICATORIA

Este trabajo está dedicado a mi
familia, por su amor, apoyo incondicional
y por ser mi fuente constante de inspiración.
A mis padres, que con su ejemplo me enseñaron
el valor del esfuerzo y la perseverancia.
A mis amigos, por su compañía y por
estar siempre ahí en los
momentos difíciles.

AGRADECIMIENTOS

La realización de este trabajo de grado representa la culminación de un extenso proceso formativo e investigativo. Este logro no habría sido posible sin el invaluable respaldo, la orientación experta y el constante apoyo de un grupo de personas a quienes deseamos expresar nuestro más profundo agradecimiento. En primer lugar, dirigimos nuestra profunda gratitud a nuestro Director el profesor Jorge Villamizar Morales, y a nuestra Codirectora, la profesora Lola Bautista. Su experta dirección, sus sabios consejos y su constante disponibilidad para resolver nuestras inquietudes fueron el faro que guió este trabajo desde su concepción hasta su finalización. De manera muy especial, queremos agradecer a nuestro tutor Sebastian Carrillo y el profesor Ivan Ortiz, cuyo acompañamiento meticuloso y apoyo práctico fueron fundamentales en el desarrollo diario de este proyecto. Su paciencia para despejar nuestras dudas y su motivación en los momentos más desafiantes fueron un pilar fundamental para mantener el rumbo y superar los obstáculos. A nuestros profesores, por haber sembrado en nosotros las bases del conocimiento y la pasión por la ingeniería a lo largo de toda nuestra carrera. A nuestras familias, por ser nuestro soporte inquebrantable. A nuestros padres, por su amor incondicional, por sus sacrificios y por creer siempre en nosotros. Este logro es tan nuestro como suyo. A nuestros amigos y compañeros de universidad, por los momentos de colaboración, por las palabras de aliento y por hacer de este camino una experiencia memorable. Finalmente, a todos aquellos que, de una u otra forma, contribuyeron a la realización de este sueño, les extendemos nuestro más sentido agradecimiento.

CONTENIDO

pág.

1 INTRODUCCIÓN 16

2 OBJETIVOS 25

3 FUNDAMENTOS Y TRABAJO PREVIO 27

3.1 IMÁGENES DEL FONDO DE OJO 27

3.2 RETINOPATÍA DIABÉTICA 30

3.3 CLASIFICACIÓN DE LA RETINOPATÍA DIABÉTICA EN IMÁGENES DEL FONDO DE OJO 30

3.4 INTELIGENCIA ARTIFICIAL 34

3.4.1 APRENDIZAJE AUTOMÁTICO 35

3.4.2 REDES NEURONALES CONVOLUCIONALES 37

3.4.3 SOBREAJUSTE Y REGULARIZACIÓN 43

3.4.4 APRENDIZAJE POR TRANSFERENCIA 46

3.5 ARQUITECTURAS DE REDES NEURONALES CONVOLUCIONALES UTILIZADAS 48

3.5.1 MOBILENETV2 48

3.5.2 RESNET50V2 50

3.5.3 INCEPTIONV3 52

3.5.4 VGG19 54

3.5.5 Comparación de arquitecturas 55

3.6 TRABAJOS PREVIOS 57

3.6.1 Enfoques con CNN personalizadas 57

3.6.2 Enfoques con arquitecturas preentrenadas 58

3.6.3 Enfoques con modificaciones arquitectónicas innovadoras 60
3.6.4 Limitaciones y brechas de investigación 61
3.6.5 Contribución del presente trabajo 62

4 METODOLOGÍA 65
4.1 CONJUNTOS DE DATOS 66
4.1.1 Dataset de Kaggle (Entrenamiento) 67
4.1.2 MESSIDOR-2 (Validación externa) 68
4.1.3 IDRiD (Validación externa) 69
4.1.4 FOSCAL (Validación externa) 69
4.1.5 Distribución de datos 70
4.1.6 División de datos para entrenamiento y validación 70
4.2 PREPROCESAMIENTO DE LAS IMÁGENES 71
4.2.1 Depuración de imágenes defectuosas 71
4.2.2 Balanceo de clases 72
4.2.3 Aumento de datos 73
4.2.4 Filtrado y realce de características 75
4.3 TECNOLOGÍAS EMPLEADAS EN EL DESARROLLO 78
4.3.1 Lenguaje de programación 78
4.3.2 Entorno de desarrollo integrado (IDE) 78
4.3.3 Bibliotecas y frameworks 79
4.3.4 Especificaciones de hardware y tiempos de entrenamiento 80
4.4 CONFIGURACIÓN EXPERIMENTAL Y ENTRENAMIENTO 81
4.4.1 Configuración común para ambos clasificadores 82
4.4.2 Configuración experimental para el clasificador binario 84
4.4.3 Configuración experimental para el clasificador multiclase 84
4.4.4 Arquitectura completa del modelo 85
4.4.5 Reproducibilidad y disponibilidad de código 86

4.5 MÉTRICAS DE EVALUACIÓN 87

5 RESULTADOS EXPERIMENTALES 90

5.1 CLASIFICACIÓN BINARIA 90

5.1.1 Comparación de arquitecturas CNN preentrenadas 90

5.1.2 Impacto del preprocesamiento mediante filtrado 92

5.1.3 Optimización del umbral de decisión 93

5.1.4 Análisis estadístico mediante bootstrap 95

5.1.5 Validación externa utilizando el mejor modelo 96

5.1.6 Comparación con trabajos previos en el estado del arte 98

5.2 CLASIFICACIÓN MULTICLASE 100

5.2.1 Resultados con imágenes RGB 100

5.2.2 Análisis comparativo por canal de color 101

5.2.3 Patrones de confusión y dificultades en clasificación multiclase 102

6 DISCUSIÓN 105

7 CONCLUSIONES 112

8 TRABAJO A FUTURO 114

BIBLIOGRAFÍA 116

LISTA DE FIGURAS

pág.

Figura 1 Distribución de la retinopatía diabética en pacientes con diabetes en los departamentos de Colombia. 18
Figura 2 Prevalencia de retinopatía diabética por sexos en Colombia 19
Figura 3 Prevalencia de retinopatía diabética por grupos de edad 20
Figura 4 Proyección de oftalmólogos en Colombia para el año 2030 21
Figura 5 Imagen del fondo de ojo mostrando estructuras anatómicas principales 29
Figura 6 Etapas de la retinopatía diabética: (a) leve, (b) moderada, (c) severa, (d) proliferativa 32
Figura 7 Estructura general de una Red Neuronal Convolucional 39
Figura 8 Ejemplo de operación de convolución utilizando un paso de 1 con un kernel de 3×3 40
Figura 9 Ejemplo de max-pooling con un paso de 2 utilizando un filtro de 2×2 41
Figura 10 Proceso de Aplanamiento (Flattening) de un Mapa de Características 43
Figura 11 Ilustración de subajuste, ajuste adecuado y sobreajuste 44
Figura 12 Arquitectura de MobileNetV2 mostrando bloques residuales invertidos 50
Figura 13 Arquitectura de ResNet50V2 con bloques residuales mejorados 51
Figura 14 Arquitectura de InceptionV3 con módulos Inception paralelos 53
Figura 15 Arquitectura de VGG19 con bloques convolucionales secuenciales 55

Figura 16 Estructura metodológica propuesta para la clasificación de retinopatía diabética mediante aprendizaje profundo 66
Figura 17 Pseudocódigo del algoritmo de preprocesamiento de Ben Graham 76
Figura 18 Ejemplo visual del proceso de preprocesamiento aplicado a una imagen de fondo de ojo 77
Figura 19 Arquitectura completa del modelo propuesto con bloques de atención y regularización 86
Figura 20 Matrices de confusión para las diferentes redes preentrenadas en clasificación binaria 92
Figura 21 Matrices de confusión para las redes preentrenadas utilizando imágenes con filtrado 94
Figura 22 Matrices de confusión del modelo MobileNetV2 con filtrado evaluado en datasets externos 97

LISTA DE TABLAS

pág.

Tabla 1 Etapas de la retinopatía diabética y sus manifestaciones clínicas observables en oftalmoscopia 33

Tabla 2 Comparación de arquitecturas CNN utilizadas en este trabajo 56

Tabla 3 Distribución de imágenes por clase de severidad de retinopatía diabética en los distintos datasets 70

Tabla 4 Configuración de transformaciones de aumento de datos aplicadas 74

Tabla 5 Distribución de clases en el conjunto de datos aumentado y balanceado 75

Tabla 6 Especificaciones de hardware y tiempos de entrenamiento 81

Tabla 7 Configuración de hiperparámetros para clasificadores binario y multiclase 83

Tabla 8 Desempeño de redes preentrenadas para clasificación binaria de retinopatía diabética usando el dataset original de Kaggle 91

Tabla 9 Comparación del rendimiento de las redes preentrenadas sin y con filtrado de imágenes 93

Tabla 10 Umbral de decisión óptimo obtenido para cada red preentrenada en clasificación binaria 94

Tabla 11 Comparación del rendimiento de las redes preentrenadas en clasificación binaria utilizando el umbral fijo (0.5) y el umbral óptimo calculado 95

Tabla 12 Intervalos de confianza (IC95 %) de las métricas de desempeño para el mejor modelo (MobileNetV2 con filtrado y umbral óptimo) 96

Tabla 13 Métricas de desempeño del modelo MobileNetV2 en validación externa 98
Tabla 14 Comparación del modelo propuesto con trabajos previos en clasificación binaria de RD 99
Tabla 15 Desempeño de redes preentrenadas para clasificación multiclase de RD según canal de color procesado 101

RESUMEN

TÍTULO: DETECCIÓN DE RETINOPATÍA DIABÉTICA EN IMÁGENES DEL FONDO DEL OJO UTILIZANDO ALGORITMOS DE APRENDIZAJE PROFUNDO *

AUTOR: CAMILO ERNESTO SERRANO LOZADA, OSCAR MAURICIO CAMPOS SEPULVEDA **

PALABRAS CLAVE: RETINOPATÍA DIABÉTICA, REDES NEURONALES CONVOLUCIONALES, APRENDIZAJE PROFUNDO, IMÁGENES DEL FONDO DEL OJO, PROCESAMIENTO DIGITAL DE IMÁGENES, APRENDIZAJE POR TRANSFERENCIA.

DESCRIPCIÓN:

La retinopatía diabética (RD) es una complicación microvascular de la diabetes que daña los vasos sanguíneos de la retina, afectando a 145 millones de personas a nivel mundial y constituyendo una de las principales causas de ceguera prevenible. En Colombia, con una proporción de 1.56 oftalmólogos por cada 100,000 habitantes y aproximadamente 1.2 millones de personas con retinopatía diabética, la detección automatizada representa una solución crítica para ampliar la cobertura del tamizaje. El diagnóstico convencional mediante exámenes de fondo de ojo resulta costoso y limitado por la disponibilidad de especialistas, especialmente en regiones con recursos médicos escasos. Este trabajo desarrolla modelos basados en redes neuronales convolucionales (CNN) para detectar la enfermedad y clasificar sus niveles de severidad mediante clasificadores binarios (presencia/ausencia) y multiclase (cinco niveles). Se utilizó aprendizaje por transferencia con las arquitecturas MobileNetV2, ResNet50V2, InceptionV3 y VGG19, entrenadas con 35,121 imágenes del dataset público de Kaggle. El preprocesamiento incluyó normalización de color, enmascaramiento periférico, balanceo de clases mediante submuestreo y aumento de datos, incorporando bloques Multi-Head Attention, capas GaussianNoise y técnicas de regularización (Dropout, L2, early stopping). El modelo fue evaluado mediante sensibilidad, precisión, F1-score y AUC-ROC, siendo MobileNetV2 con preprocesamiento mediante filtrado y umbral optimizado (0.4826) el modelo de mejor de-

---

* Trabajo de grado

** Facultad de Ingenierías Fisicomecánicas. Escuela de Ingeniería de Sistemas e Informática. Director: Jorge Villamizar Morales. Codirectores: Lola Xiomara Bautista Rozo

sempeño, alcanzando una sensibilidad de 96.5 % en clasificación binaria con intervalos de confianza bootstrap (IC95 %: AUC-ROC 0.9636–0.9936). Para clasificación multiclase, se alcanzó una exactitud de 55 % y sensibilidad de 65 %, identificando el canal verde como el más efectivo debido a su mejor contraste para lesiones hemorrágicas. La validación externa en datasets MESSIDOR-2, IDRiD y FOSCAL confirmó la capacidad de generalización del modelo, demostrando su viabilidad como herramienta de apoyo al tamizaje clínico de retinopatía diabética.

ABSTRACT

TITLE: DETECTION OF DIABETIC RETINOPATHY IN FUNDUS IMAGES USING DEEP LEARNING ALGORITHMS. *

AUTHOR: CAMILO ERNESTO SERRANO LOZADA, OSCAR MAURICIO CAMPOS SEPULVEDA **

KEYWORDS: DIABETIC RETINOPATHY, CONVOLUTIONAL NEURAL NETWORKS, DEEP LEARNING, FUNDUS IMAGES, DIGITAL IMAGE PROCESSING, TRANSFER LEARNING.

DESCRIPTION:

Diabetic retinopathy (DR) is a microvascular complication of diabetes that damages the blood vessels in the retina, affecting 145 million people worldwide and constituting one of the main causes of preventable blindness. In Colombia, with a ratio of 1.56 ophthalmologists per 100,000 inhabitants and approximately 1.2 million people with diabetic retinopathy, automated detection represents a critical solution to expand screening coverage. Conventional diagnosis through fundus examinations is costly and limited by the availability of specialists, especially in regions with scarce medical resources. This work develops models based on convolutional neural networks (CNNs) to detect the disease and classify its severity levels through binary classifiers (presence/absence) and multiclass classifiers (five levels). Transfer learning was applied using MobileNetV2, ResNet50V2, InceptionV3, and VGG19 architectures, trained with 35,121 images from the Kaggle public dataset. Preprocessing included color normalization, peripheral masking, class balancing through subsampling and data augmentation, incorporating Multi-Head Attention blocks, GaussianNoise layers, and regularization techniques (Dropout, L2, early stopping). The model was evaluated using sensitivity, precision, F1-score, and AUC-ROC, with MobileNetV2 with preprocessing through filtering and optimized threshold (0.4826) being the best-performing model, achieving 96.5 % sensitivity in binary classification with bootstrap confidence intervals (95 % CI: AUC-ROC 0.9636–0.9936). For multiclass classification, 55 %

---

* Bachelor Thesis

** Facultad de Ingenierías Fisicomecánicas. Escuela de Ingeniería de Sistemas e Informática. Advisor: Jorge Villamizar Morales. Co-advisor: Lola Xiomara Bautista Rozo

accuracy and 65 % sensitivity were achieved, identifying the green channel as most effective due to its better contrast for hemorrhagic lesions. External validation on MESSIDOR-2, IDRiD, and FOSCAL datasets confirmed the model's generalization capability, demonstrating its viability as a support tool for clinical screening of diabetic retinopathy.

1. INTRODUCCIÓN

La diabetes mellitus (DM) es una enfermedad metabólica crónica que se caracteriza por niveles elevados de glucosa en la sangre. Esto ocurre cuando el cuerpo no produce suficiente insulina, una hormona producida por el páncreas que regula la cantidad de glucosa en la sangre, o cuando las células no responden adecuadamente a la insulina. Alrededor de 463 millones de adultos entre 20 y 79 años padecen DM en la actualidad, lo que representa el 9.3 % de la población mundial en este grupo de edad [1].

La retinopatía diabética (RD) es una complicación microvascular específica de la DM que afecta a 1 de cada 3 personas con esta enfermedad, dañando los vasos sanguíneos de la retina y convirtiéndose en una de las principales causas de pérdida de visión en la población adulta activa. Los pacientes con niveles graves de RD experimentan una calidad de vida significativamente reducida y niveles más bajos de bienestar físico, emocional y social.

Con el aumento constante de personas con diabetes, la retinopatía diabética se ha convertido en una de las principales causas de pérdida de visión en todo el mundo. Según estudios publicados entre 2020 y 2022 por la Organización Mundial de la Salud (OMS), se estima que a nivel global existen alrededor de 145 millones de personas con retinopatía diabética, de las cuales aproximadamente 26 millones padecen formas graves de la enfermedad. Además, se estima que la RD es responsable de aproximadamente el 4-5 % de los casos de ceguera en todo el mundo. En muchos países, la retinopatía diabética es la causa más frecuente de ceguera evitable en

---

[1] David A Antonetti, Paolo S Silva y Alan W Stitt. «Current understanding of the molecular and cellular pathology of diabetic retinopathy». En: *Nature Reviews Endocrinology* 17.4 (2021), págs. 195-206.

adultos en edad laboral. En países desarrollados se estima que el 40 % de las personas con diabetes tipo 2 y el 86 % de las personas con diabetes tipo 1 padecen RD [2]. A pesar de la preocupación por una posible epidemia de diabetes en regiones de Asia, los datos epidemiológicos sobre la retinopatía diabética en este continente son relativamente limitados. De manera similar, en África no se han realizado estudios significativos al respecto.

A nivel regional, como indica la Federación Internacional de Diabetes (IDF) [3], en 2021 en Latinoamérica había 32 millones de personas adultas con diabetes, de las cuales el 40 % presenta algún tipo de RD y el 17 % requiere tratamiento.

A nivel nacional, la situación no difiere significativamente. Se calcula que entre un 30 % y 40 % de los pacientes con diabetes tipo 2 desarrollan RD, lo que resulta en una prevalencia de 1.2 millones de personas con RD en una población diabética de aproximadamente 4 millones de personas. Además, un estudio [4] que incluyó a 1,203 pacientes con diabetes en Colombia encontró que aproximadamente 1 de cada 3 personas con diabetes tenía retinopatía diabética y 1 de cada 10 tenía retinopatía diabética proliferativa o edema macular diabético.

Conforme al último informe publicado por el Ministerio de Salud [5], donde se analiza en Colombia la situación de la salud visual, se encuentra un alto índice de prevalen-

---

[2] Zhen Ling Teo et al. «Global prevalence of diabetic retinopathy and projection of burden through 2045: systematic review and meta-analysis». En: *Ophthalmology* 128.11 (2021), págs. 1580-1591.

[3] Hong Sun et al. «IDF Diabetes Atlas: Global, regional and country-level diabetes prevalence estimates for 2021 and projections for 2045». En: *Diabetes research and clinical practice* 183 (2022), pág. 109119.

[4] José P Vivas-Giraldo y Juan D Bravo-Acosta. «Caracterización de la retinopatía diabética en un programa de tamización en Medellín, Colombia, en el año 2018». En: *Revista mexicana de oftalmología* 95.3 (2021), págs. 118-123.

[5] Ministerio de Salud y Protección Social de Colombia. *ANÁLISIS DE SITUACIÓN DE SALUD VISUAL EN COLOMBIA*. Bogotá, Colombia, 2016.

cia de retinopatía diabética en pacientes diagnosticados con diabetes. Se observa en la Figura 1 que el departamento con el índice más alto por cada 100,000 habitantes con diabetes es el Valle del Cauca con 538.57; por su parte, Santander ocupa la quinta posición con 397.84.

Figura 1. Distribución de la retinopatía diabética en pacientes con diabetes en los departamentos de Colombia.

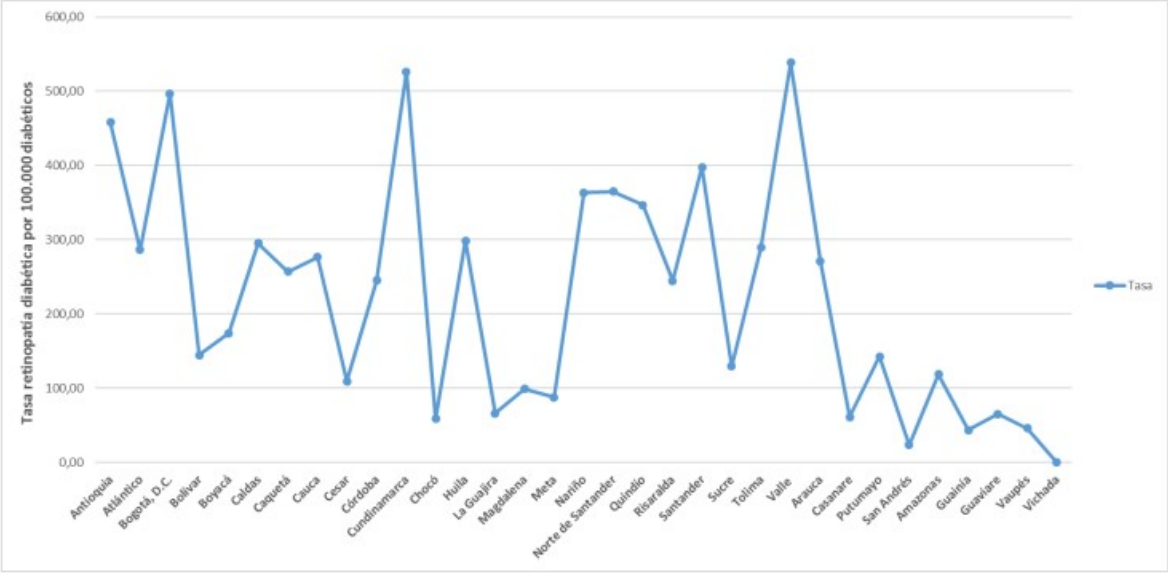

Fuente: Ministerio de Salud y Protección Social de Colombia (2016). ANÁLISIS DE SITUACIÓN DE SALUD VISUAL EN COLOMBIA, p. 84.

Al incluir la información por sexo, como se puede ver en la Figura 2, existe una prevalencia estimada para las mujeres de 19.51 por cada 100,000 habitantes, observándose un incremento de 9.1 en el transcurso de los seis años en los que se realizó el análisis. Por otro lado, en los hombres se observa una prevalencia de 16.06 por cada 100,000 habitantes, con un incremento de 6.86 a lo largo de los seis años. Cabe resaltar que este es el último informe publicado oficialmente por el gobierno, por lo que no se encontraron datos más actualizados sobre la prevalencia de la enfermedad.

Figura 2. Prevalencia de retinopatía diabética por sexos en Colombia

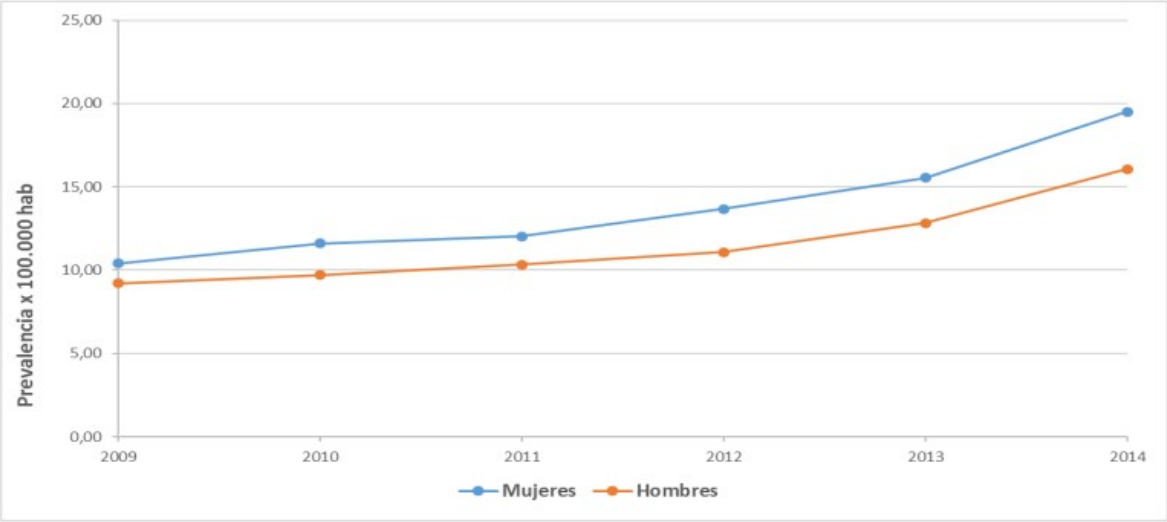

Fuente: Ministerio de Salud y Protección Social de Colombia (2016). ANÁLISIS DE SITUACIÓN DE SALUD VISUAL EN COLOMBIA, p. 81.

En las mujeres, el grupo de edad que mayor prevalencia de retinopatía diabética presentó fue el de 70-74 años, con una prevalencia estimada de 117.82 por cada 100,000 habitantes. Respecto a los hombres, el grupo de edad que mayor prevalencia obtuvo fue el de 65-69 años con una prevalencia estimada de 100.53 por cada 100,000 habitantes, tal como se observa en la Figura 3.

Estas cifras resaltan la necesidad de intervenir oportunamente para prevenir la progresión de la retinopatía diabética en la población afectada. Sin embargo, uno de los principales obstáculos es la limitada disponibilidad de médicos especialistas en oftalmología, lo que afecta especialmente a las regiones menos desarrolladas o con difícil acceso a servicios de salud visual. Según el informe realizado por la Dirección de Epidemiología y Demografía junto a la Dirección de Talento Humano en Salud de Colombia [6], en el año 2018 la proporción era de aproximadamente 1.56 oftalmólo-

[6] Diego Antonio TELLEZ Paul Rene; RESTREPO MIRANDA y Diego Alberto CUELLAR ORTIZ. *Estimación de oferta de médicos especialistas en Colombia 1950-2030 Anexo metodológico*.

gos por cada 100,000 habitantes (742/47,419,000), como se aprecia en la Figura 4, mientras que para 2030 se estima que será de aproximadamente 2.75 oftalmólogos por cada 100,000 habitantes (1,553/56,514,305). Santander es uno de los departamentos con mayor concentración de especialistas en oftalmología, contrario al caso de departamentos como San Andrés, Arauca, Amazonas, Guainía, Guaviare, Vaupés y Vichada donde no hay reporte de oftalmólogos.

Figura 3. Prevalencia de retinopatía diabética por grupos de edad

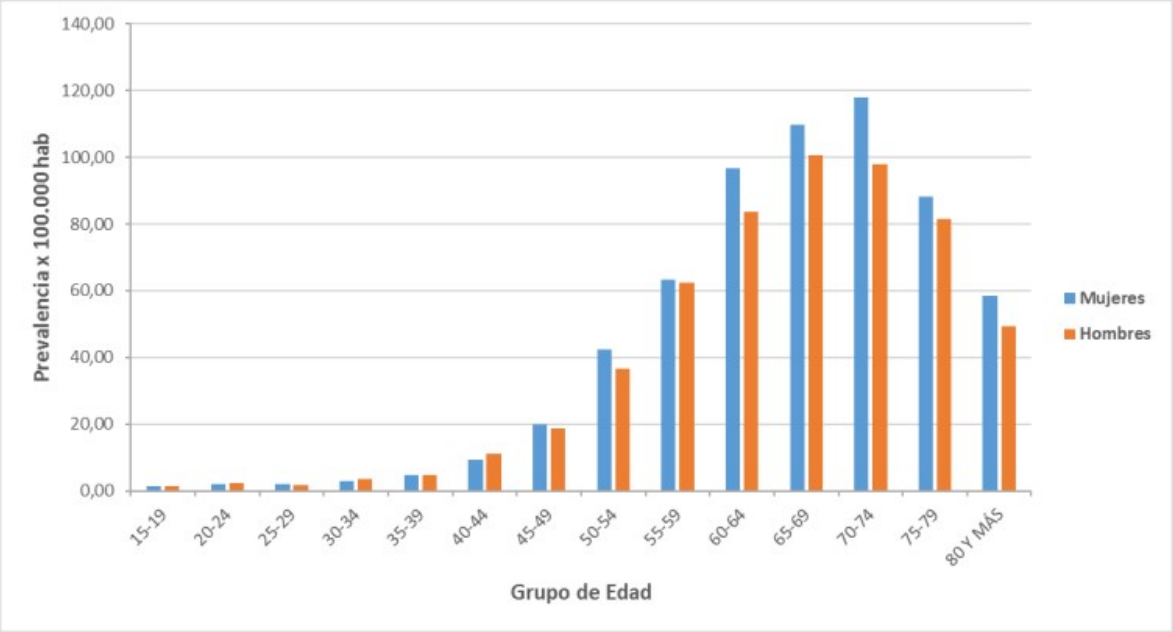

Fuente: Ministerio de Salud y Protección Social de Colombia (2016). ANÁLISIS DE SITUACIÓN DE SALUD VISUAL EN COLOMBIA, p. 82.

Bogotá, Colombia, 2018.

Figura 4. Proyección de oftalmólogos en Colombia para el año 2030

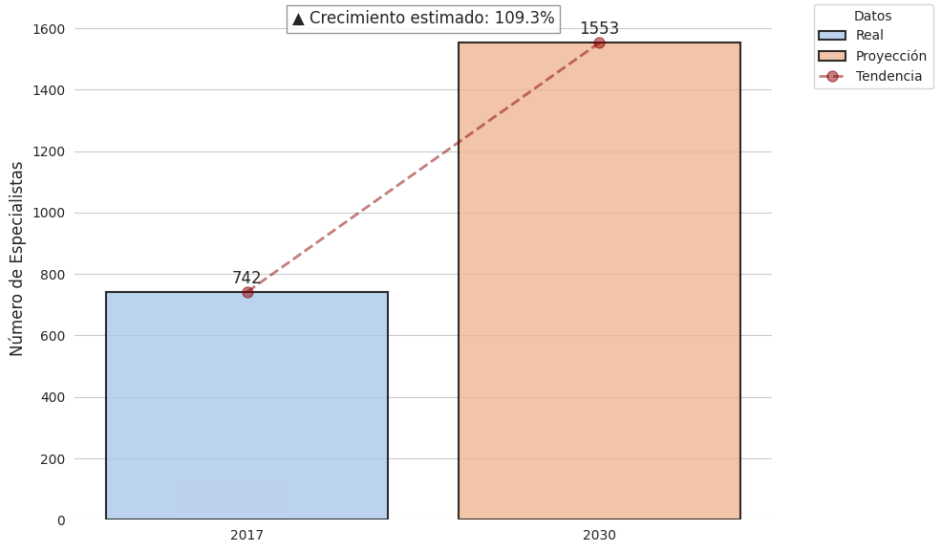

Fuente: Elaboración propia a partir de datos obtenidos por Dirección de Epidemiología y Demografía

Esta carencia de especialistas agrava el reto de diagnosticar la retinopatía diabética, especialmente en sus primeras etapas, ya que se trata de una enfermedad en gran parte asintomática en fases iniciales. El daño en los vasos sanguíneos de la retina puede progresar sin afectar directamente la visión, lo que dificulta la detección de la enfermedad cuando no se realizan revisiones periódicas del fondo de ojo. A medida que la retinopatía evoluciona a etapas más avanzadas, como la retinopatía proliferativa, comienzan a surgir síntomas visibles como visión borrosa, manchas en el campo visual o incluso pérdida de visión, señalando un daño considerable en la retina.

Este tipo de problemática requiere herramientas capaces de procesar grandes volúmenes de imágenes en poco tiempo y con alta precisión. En este contexto, las soluciones digitales ofrecen una herramienta adecuada y eficiente para este tipo de problemas. Si bien desde los años setenta existen sistemas de diagnóstico asistido

[7], es en los últimos diez años donde se ha visto una influencia e impacto mucho más significativos. Con el aumento de la capacidad de cómputo, el diseño de unidades de procesamiento gráfico dedicadas y las mejoras en los diseños de arquitecturas de redes neuronales convolucionales (CNN, por sus siglas en inglés), las soluciones digitales han tomado una relevancia de primer nivel.

Estas CNN están diseñadas para extraer características relevantes de las imágenes y aprender patrones complejos. De esta forma, con un volumen de datos lo suficientemente grande, se pueden clasificar imágenes a partir de sus características más relevantes. Investigaciones previas [8] han demostrado que este tipo de redes son capaces de lograr una detección y clasificación automatizada de la retinopatía diabética con un grado de precisión y rapidez aceptable.

Este proyecto utiliza estas redes en la construcción de clasificadores binarios (presencia o ausencia de la enfermedad) y multiclase (cinco niveles de severidad), dado que este enfoque combinado ha mostrado obtener resultados prometedores tanto para tamizaje como para gradación clínica. El modelo binario permite una rápida detección de la enfermedad, optimizando el tiempo de diagnóstico y brindando una solución viable para su implementación en escenarios de alta demanda, como en áreas con recursos limitados. Por su parte, los clasificadores multiclase aportan valor adicional en términos de tratamiento personalizado y seguimiento de los pacientes al distinguir entre los diferentes grados de severidad de la retinopatía diabética.

Una de las principales contribuciones de este proyecto es la experimentación con diferentes configuraciones de redes neuronales, explorando cómo las variaciones en el preprocesamiento y las arquitecturas afectan el desempeño del modelo. Se im-

---

[7] Víctor Arias et al. «Una introducción a las aplicaciones de la inteligencia artificial en Medicina: Aspectos históricos». En: *Revista Latinoamericana de Hipertensión* 14.5 (2019), págs. 590-600.

[8] Ibrahem Kandel y Mauro Castelli. «Transfer learning with convolutional neural networks for diabetic retinopathy image classification. A review». En: *Applied Sciences* 10.6 (2020), pág. 2021.

plementaron y compararon cuatro arquitecturas preentrenadas: MobileNetV2, ResNet50V2, InceptionV3 y VGG19, utilizando aprendizaje por transferencia con 35,121 imágenes del dataset de Kaggle para entrenamiento y datasets externos (MESSIDOR-2, IDRiD, FOSCAL) para validación. Un aspecto distintivo es el análisis de imágenes a través de los tres canales de color RGB (rojo, verde y azul) de forma independiente, un enfoque que no ha sido ampliamente explorado en investigaciones previas. La idea es determinar cuál de estos canales, por separado, proporciona la mejor representación de las características relevantes para la detección de la RD. Este análisis permitió identificar el canal verde como el más efectivo para la clasificación multiclase debido a su mejor contraste para lesiones hemorrágicas.

Adicionalmente, se implementaron distintas técnicas de regularización, como Dropout, regularización L2, capas GaussianNoise, bloques Multi-Head Attention y Data Augmentation, con el fin de reducir el sobreajuste y mejorar la generalización del modelo. Estas técnicas se evaluaron de manera exhaustiva para identificar cuáles son más efectivas en el contexto específico de clasificación de imágenes de retinopatía diabética. La combinación de estas estrategias no solo mejoró el rendimiento del modelo, sino que también contribuyó a desarrollar un sistema robusto y adaptable a diferentes tipos de datos, mejorando su aplicabilidad en diversas poblaciones. Este trabajo logró una sensibilidad de 96.5 % en clasificación binaria (con intervalos de confianza bootstrap del 95 %: AUC-ROC 0.9636–0.9936) y 55 % de exactitud con 65 % de sensibilidad en clasificación multiclase, demostrando la viabilidad de estas tecnologías para tamizaje automatizado.

Esta investigación busca impulsar el uso de tecnologías recientes en salud ocular. Su aplicación permitirá abordar la falta de especialistas en oftalmología, promover la detección oportuna de enfermedades y ampliar el alcance del diagnóstico, optimizando así la eficiencia y accesibilidad de los servicios de salud visual. Además, esta metodología podría sentar las bases para implementar soluciones similares en

otros países en vías de desarrollo, generando un impacto significativo en la calidad de vida de los pacientes.

El presente documento se estructura de la siguiente manera: en el Capítulo 3 se presentan los fundamentos teóricos y el estado del arte; el Capítulo 2 detalla los objetivos del trabajo; el Capítulo 4 describe la metodología implementada; los Capítulos **??** y 5 exponen la configuración experimental y los resultados obtenidos; y finalmente, los Capítulos **??**, **??** y **??** presentan la discusión, conclusiones y trabajo futuro respectivamente.

2. OBJETIVOS

Objetivo general

Desarrollar e implementar algoritmos de clasificación automática basados en aprendizaje profundo para la detección y gradación de severidad de retinopatía diabética en imágenes del fondo del ojo, mediante redes neuronales convolucionales con aprendizaje por transferencia.

Objetivos específicos

OE1. Realizar una revisión sistemática de la literatura científica sobre la detección de retinopatía diabética utilizando técnicas de aprendizaje profundo, identificando las arquitecturas preentrenadas más efectivas, técnicas de preprocesamiento y métricas de evaluación estándar en el dominio.

OE2. Recopilar y consolidar conjuntos de datos de imágenes de fondo de ojo etiquetadas, integrando datasets públicos (Kaggle, MESSIDOR-2, IDRiD) y privados (FOSCAL), alcanzando un mínimo de 35,000 imágenes para entrenamiento y 3 datasets externos para validación.

OE3. Implementar y evaluar técnicas de preprocesamiento de imágenes (normalización de color, enmascaramiento periférico, balanceo de clases) y aumento de datos para optimizar la calidad del conjunto de entrenamiento y mitigar el desbalance entre clases.

OE4. Implementar y comparar cuatro arquitecturas de redes neuronales convolucionales preentrenadas (MobileNetV2, ResNet50V2, InceptionV3, VGG19) mediante aprendizaje por transferencia, incorporando técnicas de regularización

(Dropout, L2, GaussianNoise, Multi-Head Attention) para prevenir sobreajuste.

OE5. Desarrollar un clasificador binario optimizado para detección de presencia/ausencia de retinopatía diabética, alcanzando una sensibilidad mínima del 90 % con optimización del umbral de decisión.

OE6. Desarrollar un clasificador multiclase para gradación de severidad de retinopatía diabética en cinco niveles (0: sin RD, 1: leve, 2: moderada, 3: severa, 4: proliferativa), analizando el desempeño diferencial de los canales de color RGB procesados independientemente.

OE7. Analizar comparativamente el desempeño de los modelos al procesar imágenes RGB completas versus canales de color individuales (rojo, verde, azul), identificando el canal más efectivo para la detección de lesiones específicas de retinopatía diabética.

OE8. Evaluar el desempeño de los modelos desarrollados utilizando métricas clínicas estándar (sensibilidad, especificidad, precisión, F1-score, AUC-ROC) con intervalos de confianza bootstrap, asegurando rigor estadístico en la presentación de resultados.

OE9. Validar la capacidad de generalización de los modelos mediante evaluación en datasets externos independientes (MESSIDOR-2, IDRiD, FOSCAL) con diferentes características de adquisición y distribución de clases.

OE10. Comparar el desempeño de los modelos desarrollados con trabajos previos reportados en la literatura científica, posicionando los resultados obtenidos dentro del contexto del estado del arte en detección automatizada de retinopatía diabética.

3. FUNDAMENTOS Y TRABAJO PREVIO

El desarrollo de sistemas automatizados para la detección y clasificación de retinopatía diabética mediante técnicas de aprendizaje profundo requiere una comprensión sólida de múltiples dominios del conocimiento. Este capítulo presenta los fundamentos teóricos y el estado del arte que sustentan el presente trabajo, organizados en cuatro componentes principales: primero, se describe la naturaleza y características de las imágenes de fondo de ojo, el principal insumo del sistema propuesto; segundo, se expone la fisiopatología y clasificación clínica de la retinopatía diabética; tercero, se desarrollan los conceptos fundamentales de inteligencia artificial, aprendizaje automático y redes neuronales convolucionales que constituyen la base metodológica del trabajo; y finalmente, se presenta una revisión sistemática de los trabajos previos en el área, identificando enfoques, resultados y las brechas de investigación que este trabajo pretende abordar.

3.1. IMÁGENES DEL FONDO DE OJO

Las imágenes de fondo de ojo, también conocidas como retinografías o imágenes de retina, son fotografías detalladas de la parte posterior del ojo que permiten observar estructuras clave como la retina, el nervio óptico, los vasos sanguíneos y la mácula. Estas imágenes son fundamentales en oftalmología para el diagnóstico y seguimiento de diversas enfermedades oculares, como la retinopatía diabética, el glaucoma, la degeneración macular y otros trastornos retinianos. A través del análisis de estas imágenes, los médicos pueden detectar alteraciones en los vasos sanguíneos, signos de inflamación o daño estructural en la retina, lo que puede ser indicativo de enfermedades en progresión.

El proceso de captura de estas imágenes se realiza mediante un examen médico

no invasivo, en el cual se emplea un oftalmoscopio o una cámara de fondo de ojo especializada. Este instrumento emite una luz que atraviesa las pupilas y permite al especialista examinar directamente la retina, los vasos sanguíneos y el nervio óptico. En la mayoría de los casos, se requiere la dilatación de las pupilas para mejorar la visualización, especialmente si se utiliza una cámara de fondo de ojo avanzada. Aunque la captura de estas imágenes no es dolorosa, puede llevar algunos minutos, dependiendo de la tecnología utilizada.

Existen varias técnicas para realizar la oftalmoscopia, cada una con sus características y ventajas. La importancia de estas imágenes en la práctica clínica es incuestionable. En algunos estudios [9] se ha destacado cómo el análisis de la imagen del fondo de ojo es crucial para la detección temprana de la retinopatía diabética, lo que permite la intervención oportuna y la prevención de la pérdida de visión. Esta capacidad de detectar cambios sutiles en la estructura ocular antes de que se presenten síntomas graves resalta la utilidad de las imágenes de fondo de ojo en la medicina preventiva.

---

[9] Tien Y Wong et al. «Prevalence and risk factors for diabetic retinopathy: the Singapore Malay Eye Study». En: *Ophthalmology* 115.11 (2008), págs. 1869-1875.

Figura 5. Imagen del fondo de ojo mostrando estructuras anatómicas principales

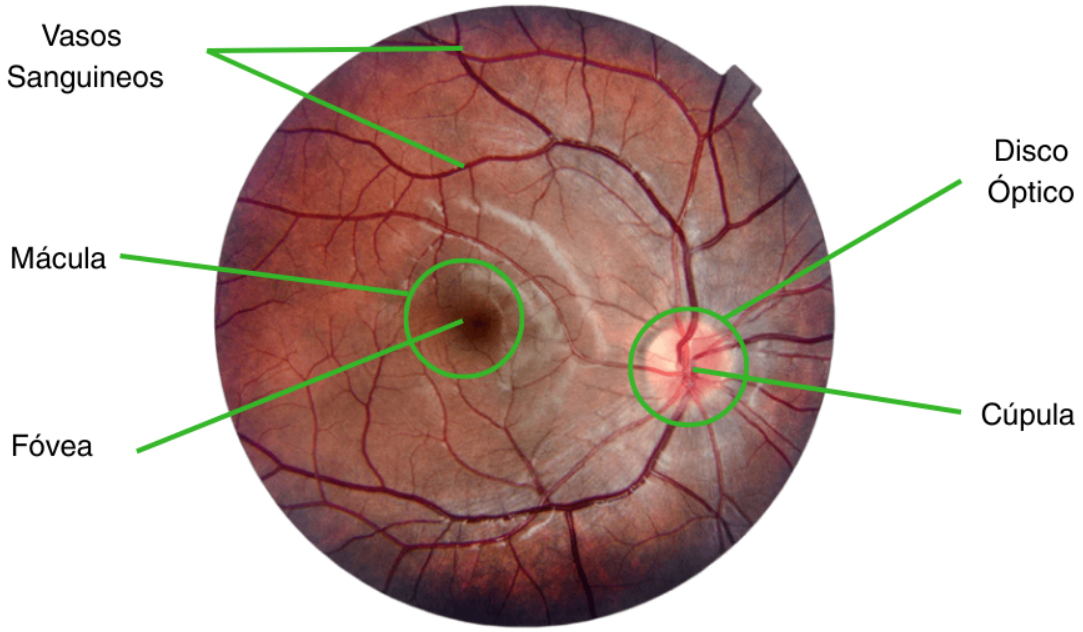

Fuente: Elaboración propia

En la actualidad podemos encontrar otros tipos de exámenes que pueden ayudar a detectar la retinopatía diabética. Entre los más conocidos está el examen con lámpara de hendidura, que permite observar la parte frontal del ojo y la retina; y la tomografía de coherencia óptica (OCT), que toma secciones transversales de la retina y es útil para evaluar el grosor y detectar edema macular. Sin embargo, las imágenes del fondo de ojo son las más utilizadas en la detección de la RD debido a que proporcionan una visualización directa de la retina, donde se producen los cambios patológicos característicos, y son relativamente fáciles de interpretar, lo que permite un diagnóstico rápido. Además, con el avance de la inteligencia artificial, estas imágenes pueden ser analizadas automáticamente mediante algoritmos de aprendizaje profundo, permitiendo un tamizaje masivo y eficiente.

3.2. RETINOPATÍA DIABÉTICA

La retinopatía diabética es una complicación ocular de la diabetes que se produce debido al daño en los vasos sanguíneos de la retina, el tejido sensible a la luz en la parte posterior del ojo. Este daño es causado principalmente por niveles elevados de glucosa en la sangre, que pueden obstruir los pequeños vasos sanguíneos que alimentan la retina. Este daño hace que los vasos sanguíneos se vuelvan más permeables y propensos a filtrar líquido y sangre en la retina. Además, los vasos sanguíneos pueden hincharse y formar microaneurismas, que son pequeñas protuberancias en los vasos sanguíneos que pueden romperse y sangrar.
Esta enfermedad puede tener consecuencias graves para la visión. Una de las complicaciones más comunes es el sangrado dentro del ojo, que ocurre cuando se forman vasos sanguíneos anormales que se rompen y liberan sangre en el interior del ojo. Este sangrado puede hacer que la visión se vuelva borrosa o incluso se pierda completamente si es muy grande. Otra complicación seria es el desprendimiento de la retina. Los vasos sanguíneos anormales pueden generar tejido cicatricial que tira de la retina, lo que puede hacer que se separe de la parte posterior del ojo.

3.3. CLASIFICACIÓN DE LA RETINOPATÍA DIABÉTICA EN IMÁGENES DEL FONDO DE OJO

Los signos microvasculares retinianos clásicos incluyen microaneurismas, hemorragias, exudados duros, manchas de algodón, dilatación venosa y perlas, así como diversas anomalías microvasculares intrarretinianas. En las etapas iniciales de la enfermedad, muchos de estos síntomas no se manifiestan de manera evidente, lo que hace que el diagnóstico temprano sea más desafiante. Por esta razón, se recomienda que los pacientes diabéticos se sometan a exámenes regulares de fondo de ojo, incluso si no experimentan síntomas. La detección temprana es fundamental,

ya que permite la intervención antes de que la enfermedad progrese, lo que brinda una mayor oportunidad para un tratamiento eficaz, reduce el riesgo de ceguera y atenúa las complicaciones asociadas a la retinopatía diabética.

La retinopatía diabética se clasifica en dos formas principales: la retinopatía diabética no proliferativa (RDNP) y la retinopatía diabética proliferativa (RDP), cada una con características particulares que influyen en el manejo clínico y el pronóstico de la enfermedad. En la RDNP, los cambios en los vasos sanguíneos retinianos son generalmente más leves e incluyen microaneurismas, hemorragias y exudados duros. Aunque estos signos pueden no afectar gravemente la visión en sus primeras etapas, la progresión sin tratamiento adecuado puede derivar en la forma proliferativa.

El diagnóstico oportuno es crucial, ya que un control adecuado de los niveles de glucosa en sangre y la detección temprana de la enfermedad pueden retrasar o incluso evitar el avance hacia formas más graves de retinopatía. Además, estudios han demostrado que los pacientes que se someten a exámenes regulares de fondo de ojo tienen una mejor tasa de preservación de la visión a largo plazo [10].

---

[10] Michael Cusick et al. «Associations of mortality and diabetes complications in patients with type 1 and type 2 diabetes: early treatment diabetic retinopathy study report no. 27». En: *Diabetes Care* 28.3 (2005), págs. 617-625.

Figura 6. Etapas de la retinopatía diabética: (a) leve, (b) moderada, (c) severa, (d) proliferativa

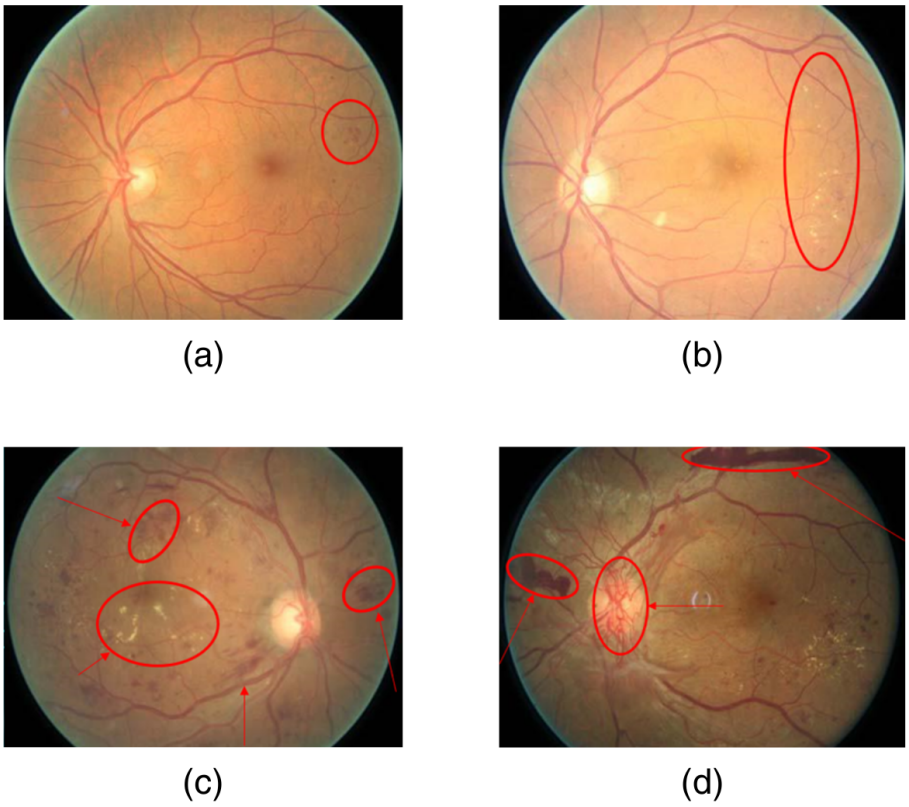

Fuente: Adaptado de clasificación clínica estándar de retinopatía diabética

La retinopatía diabética no proliferativa progresa en varias etapas, como se observa en la Figura 6. En la etapa leve (Figura 6a), los pequeños vasos sanguíneos de la retina comienzan a debilitarse y desarrollan microaneurismas, pequeñas protuberancias en las paredes de los vasos, y puede haber una leve obstrucción que dificulta el suministro de oxígeno y nutrientes a la retina. En la etapa moderada (Figura 6b), el deterioro de los vasos sanguíneos se intensifica, apareciendo más microaneurismas junto con pequeñas hemorragias y exudados, que son acumulaciones de líquido y proteínas en la retina; también pueden observarse un engrosamiento de las paredes de los vasos y una disminución en la circulación sanguínea. En la etapa severa

(Figura 6c), los daños en los vasos sanguíneos son más significativos, causando una disminución del flujo sanguíneo a la retina, hemorragias mayores y exudados extensos, así como la formación de tejido fibroso que puede llevar a la tracción y desprendimiento de la retina. Finalmente, en la etapa proliferativa o retinopatía diabética proliferativa (RDP) (Figura 6d), los nuevos vasos sanguíneos crecen anormalmente en la retina, lo que crea presión en el globo ocular y puede hacer que la retina se desprenda. Además, la sangre se filtra en el vítreo, lo que daña el nervio óptico, responsable de transmitir imágenes al cerebro, provocando pérdida de visión.

Tabla 1. Etapas de la retinopatía diabética y sus manifestaciones clínicas observables en oftalmoscopia

Etapa	**Hallazgos observables en la oftalmoscopia**
Sin retinopatía aparente	Sin anomalías
RD no proliferativa leve	Solo microaneurismas
RD no proliferativa moderada	Más microaneurismas
RD no proliferativa severa	Hemorragias intrarretinianas mayor a 20 en cada cuadrante. Anomalías microvasculares intrarretinianas (en 1 cuadrante)
RD proliferativa	Neovascularización Hemorragia vítrea prerretiniana

3.4. INTELIGENCIA ARTIFICIAL

El estudio de la inteligencia artificial (IA) ha sido una disciplina en constante evolución durante más de 65 años, impulsada por el esfuerzo conjunto de científicos e ingenieros. El principio fundamental detrás de la IA es que las máquinas, creadas por el ser humano, pueden ir más allá de realizar tareas repetitivas o intensivas, desarrollando una forma de inteligencia que imita o incluso supera ciertas capacidades humanas [11].

Uno de los aspectos más destacados de la IA es su capacidad para cambiar el paradigma tradicional de los algoritmos. En la programación convencional, los datos de entrada son procesados por un conjunto de reglas predefinidas por el programador, lo que da como resultado una salida determinada. En contraste, los sistemas de inteligencia artificial operan mediante un enfoque de aprendizaje automático, donde se proporcionan conjuntos de datos de entrada y salida, pero el algoritmo debe aprender por sí mismo las reglas y patrones subyacentes que relacionan ambos conjuntos. Esto permite que el programa sea capaz de inferir correlaciones entre datos y, con el tiempo, adaptar su comportamiento, mejorando su precisión y eficiencia sin intervención humana directa.

En el ámbito de la medicina, la inteligencia artificial ha mostrado un crecimiento impresionante y continúa ganando terreno. Año tras año se incrementa su uso, a medida que los avances en la ciencia computacional permiten desarrollar tecnologías más sofisticadas y eficaces. Un ejemplo de ello son los robots quirúrgicos, que realizan procedimientos con una precisión milimétrica, minimizando riesgos y mejorando los tiempos de recuperación. Asimismo, se han creado sistemas de IA que analizan grandes cantidades de datos clínicos para clasificar y diagnosticar enfer-

---

[11] Yuchen Jiang et al. «Quo vadis artificial intelligence?» En: *Discover Artificial Intelligence* 2.1 (2022), pág. 4.

medades con una exactitud comparable a la de los expertos humanos [12]. Además, la IA también se está utilizando para predecir brotes epidémicos, personalizar tratamientos médicos y mejorar la gestión de los servicios de salud en general. A medida que la investigación avanza, es probable que veamos aplicaciones aún más innovadoras de la IA, que no solo transformarán la manera en que abordamos la medicina, sino que también influirán en una gran cantidad de otras industrias.

3.4.1. APRENDIZAJE AUTOMÁTICO El aprendizaje automático (machine learning) es un subcampo de la inteligencia artificial que ha transformado profundamente la manera en la que interactuamos con la tecnología. Se refiere a la capacidad de las máquinas de aprender a partir de los datos que se les proporcionan, sin necesidad de ser programadas de manera explícita para cada tarea específica. Estos sistemas utilizan algoritmos matemáticos complejos para identificar patrones dentro de grandes volúmenes de datos, y luego emplean esos patrones para hacer predicciones o tomar decisiones autónomas.

El proceso de aprendizaje automático comienza con la recopilación de datos, que es crucial para obtener resultados precisos. La calidad de los datos tiene una influencia directa sobre el rendimiento del modelo, por lo que es fundamental que los datos sean representativos, completos y correctos. En muchas ocasiones, los datos deben ser preprocesados para asegurar que se encuentren en una forma adecuada para ser procesados por los algoritmos, lo que incluye tareas como la normalización, la eliminación de valores atípicos o la imputación de datos faltantes.

Existen diversos tipos de algoritmos de aprendizaje automático, entre los cuales destacan la clasificación, regresión y clustering, y la selección del algoritmo adecua-

---

[12] Varun Gulshan et al. «Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs». En: *JAMA* 316.22 (2016), págs. 2402-2410. DOI: 10.1001/jama.2016.17216.

do depende del tipo de problema que se desee resolver. Una vez que se cuenta con los datos preparados, se procede a entrenar el modelo ajustando sus parámetros internos de manera que se minimicen los errores en las predicciones. Durante este proceso, el modelo aprende a realizar la tarea que se le ha asignado, mejorando su capacidad para generalizar a datos que no haya visto previamente. Finalmente, el rendimiento del modelo se evalúa utilizando un conjunto de datos de prueba, lo que permite verificar que el modelo sea capaz de generalizar bien y no esté simplemente memorizando los datos de entrenamiento.

Dentro del campo del aprendizaje automático, existen diferentes tipos o enfoques según la estructura de los datos y el tipo de tarea que se desea realizar. Los principales son: el aprendizaje supervisado, el no supervisado, el semisupervisado y el aprendizaje por refuerzo. En el aprendizaje supervisado se realiza el entrenamiento utilizando un conjunto de datos etiquetado, es decir, datos para los cuales ya se conoce la salida correcta. El objetivo es que el modelo pueda mapear nuevas entradas a sus respectivas salidas correctas (etiquetas). Los modelos de clasificación y regresión son ejemplos típicos de aprendizaje supervisado. En clasificación, el objetivo es asignar una etiqueta a un conjunto de datos (por ejemplo, determinar si una imagen contiene un perro o un gato), mientras que en regresión el objetivo es predecir un valor continuo (como el precio de una casa en función de características como su tamaño y ubicación) [13].

Por otro lado, en el aprendizaje no supervisado el modelo trabaja con un conjunto de datos que no tiene etiquetas, y el objetivo es identificar patrones ocultos dentro de los datos. Por ejemplo, el modelo puede buscar agrupaciones de datos similares (clustering) o intentar reducir la cantidad de características necesarias para representar los datos (reducción de dimensionalidad). Este tipo de aprendizaje se utiliza

---

[13] Michael I Jordan y Tom M Mitchell. «Machine learning: Trends, perspectives, and prospects». En: *Science* 349.6245 (2015), págs. 255-260.

ampliamente en análisis exploratorio de datos y en tareas como la segmentación de clientes o la detección de anomalías.

En el enfoque del aprendizaje semisupervisado se combinan elementos del aprendizaje supervisado y no supervisado. En este caso, el conjunto de datos contiene tanto ejemplos etiquetados como no etiquetados. Este enfoque es útil cuando etiquetar grandes cantidades de datos es costoso o impráctico, pero se dispone de un pequeño conjunto de datos etiquetados para guiar el proceso de aprendizaje. Los algoritmos semisupervisados intentan aprovechar los datos no etiquetados para mejorar el rendimiento general del modelo.

Por último, el aprendizaje por refuerzo se basa en el concepto de recompensa y penalización. En este paradigma, un agente toma decisiones en un entorno y recibe recompensas o penalizaciones en función de las acciones que realiza. El objetivo es que el agente aprenda a tomar decisiones que maximicen la recompensa acumulada a largo plazo. Este enfoque se utiliza en tareas complejas donde las decisiones deben tomarse en secuencia, como en la robótica, el juego de ajedrez o la conducción autónoma.

3.4.2. REDES NEURONALES CONVOLUCIONALES En el campo de la visión por computadora, las redes neuronales convolucionales (CNN, por sus siglas en inglés) y sus posteriores mejoras han representado un hito crucial en el procesamiento de imágenes. El uso de estas fue popularizado por el trabajo de Yann LeCun y colaboradores en 1998 [14]. Antes de la aparición de las CNN, las redes neuronales artificiales tradicionales tenían limitaciones significativas para trabajar con datos de más de una dimensión, como es el caso de las imágenes. Las redes neuronales convencionales están diseñadas para procesar arreglos numéricos unidimensiona-

[14] Yann LeCun et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* 86.11 (1998), págs. 2278-2324.

les. Estos arreglos no son ideales para procesar imágenes, las cuales, al ser tratadas por un computador, se representan como matrices bidimensionales de valores numéricos (en el caso de las imágenes en escala de grises) o tridimensionales (para imágenes en color).

Para que una red neuronal tradicional pueda procesar imágenes, debe aplanar estas matrices multidimensionales, convirtiéndolas en un arreglo unidimensional. Este proceso implica perder la relación espacial entre los píxeles vecinos, lo que resulta en una pérdida significativa de información contextual, esencial para tareas de clasificación y detección de patrones. Como resultado, el modelo es menos efectivo al capturar características importantes que dependen de la estructura espacial de los datos.

Mientras que las redes neuronales convolucionales resuelven este problema al procesar las imágenes en su formato original de múltiples dimensiones. Una CNN utiliza una operación denominada convolución, que consiste en aplicar un filtro (o kernel) a lo largo de la imagen. Este filtro también es un arreglo de varias dimensiones que se desplaza sobre la imagen, realizando una operación de multiplicación elemento a elemento entre el filtro y las porciones de la imagen con las que coincide. El filtro çaptura"patrones locales, como bordes, texturas o formas, y extrae información relevante de estas coincidencias. Al repetir este proceso a través de diferentes áreas de la imagen, se generan mapas de características que preservan las relaciones espaciales y las características locales de la imagen. El resultado final es una representación más rica y estructurada de la imagen, que proporciona una mejor base para tareas de clasificación, segmentación o reconocimiento de patrones.

Una red neuronal convolucional profunda, o CNN profunda, está compuesta por múltiples capas organizadas en una estructura jerárquica. Cada capa tiene una función específica que contribuye al proceso de extracción de características y toma de decisiones.

Figura 7. Estructura general de una Red Neuronal Convolucional

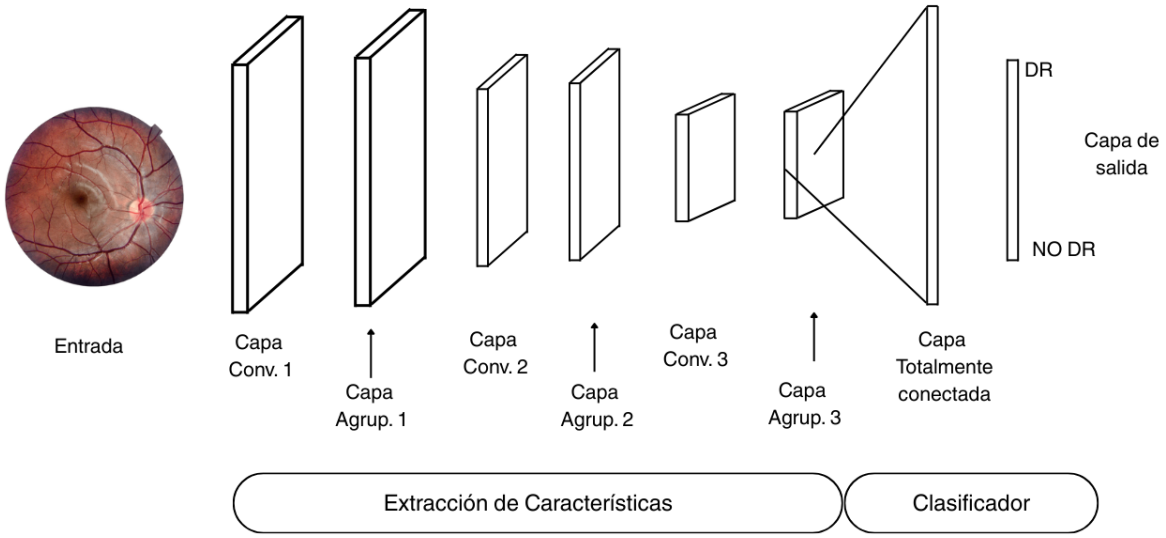

Fuente: Adaptado de arquitecturas CNN estándar

Capa convolucional: Es la primera capa de cada modelo CNN. Una capa convolucional tiene varios filtros de tamaño $M \times M$, cada uno de los cuales realiza la operación de convolución. El producto escalar se toma entre el filtro y las partes cubiertas por el filtro en la imagen de entrada, deslizando el filtro sobre la imagen. El resultado se denomina mapa de características. A través de este proceso se pueden identificar esquinas y bordes. Más adelante, este mapa de características se traslada y se alimenta a otras capas para aprender características más complejas que no se identificaron inicialmente.

Figura 8. Ejemplo de operación de convolución utilizando un paso de 1 con un kernel de 3×3

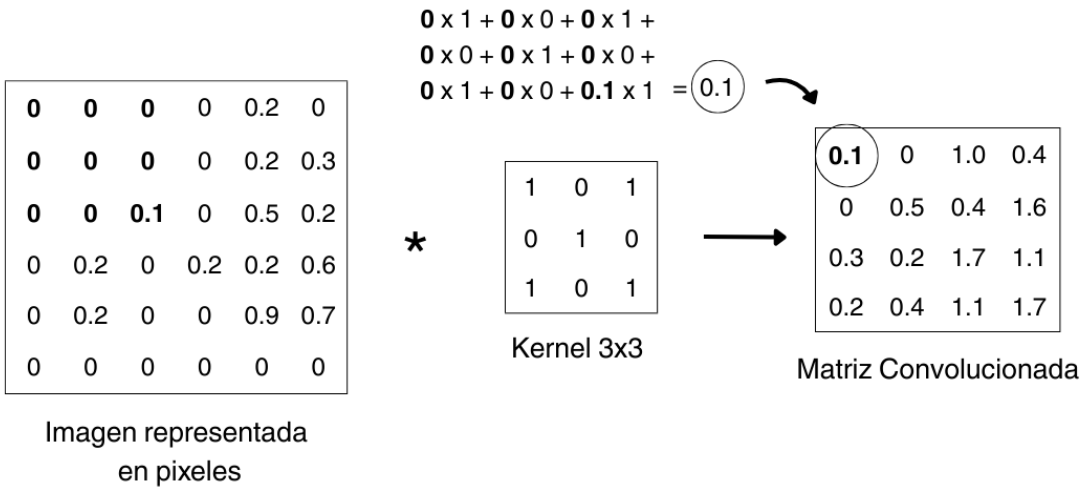

Fuente: Adaptado de operaciones estándar de CNN

Función de activación: Se aplica una función de activación después de cada operación de convolución. Esta función ayuda a la red a aprender relaciones no lineales entre las características de la imagen, lo que hace la red más robusta para identificar distintos patrones. También ayuda a mitigar el problema de desvanecimiento de gradiente. Las funciones de activación más comunes incluyen ReLU (Rectified Linear Unit), Sigmoid y Tanh.

Capa de agrupamiento: La capa de agrupación (también llamada pooling) va después de una capa de convolución, y su propósito es reducir el tamaño espacial del mapa de características, es decir, su ancho y alto [15]. Este proceso disminuye el costo computacional y ayuda a condensar la información local. Las operaciones de agrupación se aplican a secciones del mapa de características y producen una versión reducida que conserva lo más importante. Las variantes más usadas son:

---

[15] İsmail Akgül. «A pooling method developed for use in convolutional neural networks». En: *CMES-Computer Modeling in Engineering and Sciences* 141.1 (2024).

- **Max pooling:** para cada sección, selecciona el valor más alto.
- **Average pooling:** calcula la media de los valores en la sección.
- **Min pooling:** selecciona el valor más bajo en cada sección.

Figura 9. Ejemplo de max-pooling con un paso de 2 utilizando un filtro de 2×2

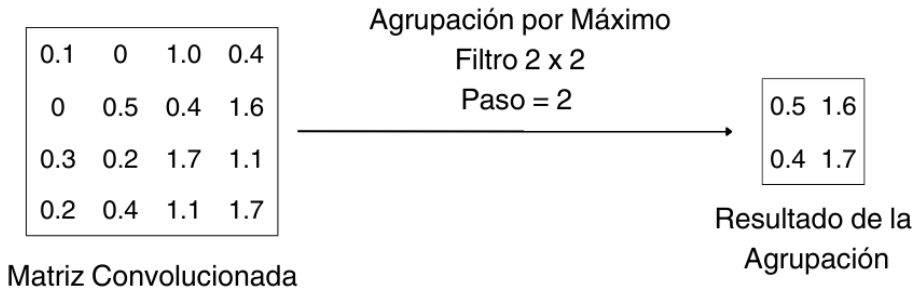

Fuente: Adaptado de operaciones estándar de pooling

Capa Multi-Head Attention: Este tipo de bloques fueron introducidos por primera vez en la arquitectura de transformers [16]. En esencia, son un mecanismo que permite a un modelo de IA enfocarse en diferentes partes de una secuencia de datos y analizar las partes más determinantes de la misma. Estos bloques se componen de varias çabezas de atención", por lo que es posible observar los datos desde múltiples perspectivas. Cada cabeza de atención trabaja con tres elementos principales: Q (queries), K (keys) y V (values), que son representaciones diferentes de la misma información de entrada.

En visión computacional, la atención se ha usado de dos maneras complementarias: como sustituto completo de las convoluciones en arquitecturas tipo ViT (Vision Transformer) para procesar secuencias de parches, y como complemento de redes

[16] Ashish Vaswani et al. «Attention is all you need». En: *Advances in neural information processing systems* 30 (2017).

convolucionales, concatenando o integrando mapas de características de atención con los mapas convolucionales para incorporar contexto no local. En particular, trabajos que integran atención con CNNs han mostrado mejoras consistentes en clasificación y detección, incluso en arquitecturas diseñadas para dispositivos móviles [17].

Capa GaussianNoise: Este tipo de capas aplican durante el entrenamiento una perturbación aditiva. En términos generales, cada valor de la activación de la capa recibe ruido gaussiano aleatorio durante la fase de entrenamiento y la capa queda inactiva durante la inferencia. Esta acción puede interpretarse como una forma de aumento estocástico aplicado a las características internas de la red y como un regularizador que evita el sobreajuste al exponer al modelo a versiones ligeramente corruptas de las representaciones aprendidas. En redes con backbones preentrenados, las capas añadidas para clasificación suelen contener muchos parámetros nuevos y son especialmente propensas a sobreajustarse cuando los datos etiquetados disponibles son limitados. Introducir ruido gaussiano sobre el mapa de características sirve para forzar a que el clasificador aprenda patrones robustos y no dependientes de valores exactos de activación, y para simular variabilidad propia de la adquisición de imágenes (ruido del sensor, diferencias de iluminación o preprocesado). Estudios empíricos en problemas clínicos y de visión han mostrado mejoras en métricas de generalización y AUC cuando se usa inyección de ruido [18].

Capa completamente conectada: La capa completamente conectada (FC) está formada por pesos, sesgos y neuronas. Actúa como un puente que conecta las neuronas que están presentes entre las capas ocultas y las capas de salida. Estas

---

[17] Alexey Dosovitskiy et al. «An image is worth 16x16 words: Transformers for image recognition at scale». En: *arXiv preprint arXiv:2010.11929* (2020).

[18] Richard M Zur et al. «Noise injection for training artificial neural networks: A comparison with weight decay and early stopping». En: *Medical physics* 36.10 (2009), págs. 4810-4818.

capas se colocan solo unas pocas capas antes de la capa de salida. El mapa de características de la capa anterior se aplana para crear un único vector de características largo. El vector aplanado se pasa a otras capas completamente conectadas en las que se realizan muchas operaciones matemáticas. El proceso de clasificación comienza en esta etapa. La Figura 10 muestra un ejemplo de proceso de aplanamiento que convierte las características en una única dimensión.

Figura 10. Proceso de Aplanamiento (Flattening) de un Mapa de Características

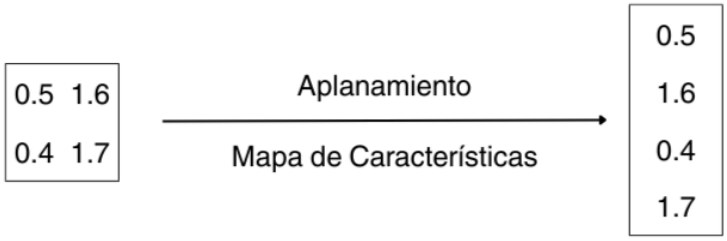

Fuente: Elaboración propia

3.4.3. SOBREAJUSTE Y REGULARIZACIÓN El sobreajuste (overfitting) es un problema habitual en los modelos de aprendizaje automático. Ocurre cuando el modelo aprende demasiado los datos de entrenamiento, incluyendo su ruido y sus valores atípicos, lo que se conoce como .ªprendizaje de memoria". Un aprendizaje de este tipo conduce a un modelo que funciona bien con los datos de entrenamiento, pero mal con nuevos datos no vistos. Por el contrario, el subajuste (underfitting) ocurre cuando el modelo es demasiado simple para capturar los patrones subyacentes en los datos.

Figura 11. Ilustración de subajuste, ajuste adecuado y sobreajuste

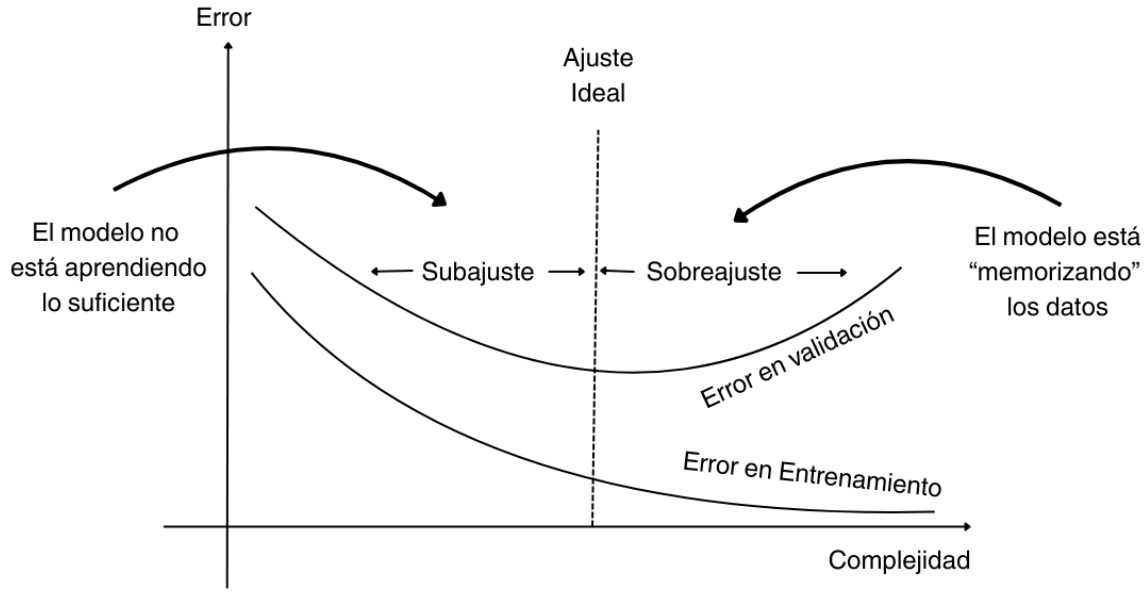

Fuente: Adaptado de conceptos estándar de machine learning

Los modelos de aprendizaje profundo, especialmente las redes neuronales convolucionales (CNN), son especialmente susceptibles al sobreajuste debido a su alta capacidad y su habilidad para aprender patrones detallados en datos a gran escala. Existen varias técnicas de regularización para mitigar el sobreajuste en las CNN. Entre las más comunes encontramos:

Dropout (Abandono): Esta técnica se basa en desactivar aleatoriamente una proporción de neuronas durante el entrenamiento, lo que obliga a la red a no depender excesivamente de neuronas específicas y promueve una representación más robusta de los datos [19]. Típicamente, el porcentaje que se desactiva suele variar entre 0.2 y 0.5. Durante el entrenamiento, las conexiones de las neuronas desactivadas se

[19] Christian Garbin, Xingquan Zhu y Oge Marques. «Dropout vs. batch normalization: an empirical study of their impact to deep learning». En: *Multimedia tools and applications* 79.19 (2020), págs. 12777-12815.

eliminan temporalmente, lo que resulta en una red más ligera en cada paso de entrenamiento. La implementación de esta técnica ha mostrado ser particularmente efectiva en redes densamente conectadas para mejorar la generalización.

Normalización por lotes (Batch Normalization): El sobreajuste se reduce en cierta medida normalizando la capa de entrada mediante el ajuste y la escala de las activaciones. Este enfoque también se utiliza para acelerar y estabilizar el proceso de entrenamiento al reducir la covarianza interna del modelo.

Capas de agrupamiento (Pooling): Estas capas pueden utilizarse para reducir las dimensiones espaciales de la imagen de entrada y proporcionar al modelo una forma abstracta de representación, reduciendo así la posibilidad de sobreajuste al disminuir el número de parámetros.

Parada Anticipada (Early Stopping): Esta técnica consiste en monitorear el rendimiento del modelo en un conjunto de validación durante el proceso de entrenamiento y detenerlo cuando dicho rendimiento deja de mejorar. Así se evita que el modelo se ajuste demasiado a los datos de entrenamiento y pierda capacidad de generalización. Este método ha sido probado en distintas investigaciones [20], donde se demuestra que el early stopping puede reducir el sobreajuste y mejorar la generalización de las redes neuronales profundas.

Inyección de ruido: Este proceso consiste en añadir ruido a las entradas o a las salidas de las capas ocultas durante el entrenamiento para hacer más robusto el modelo e impedir que generalice débilmente.

Regularización L1 y L2: La regularización L2 consiste en agregar un término de penalización a la función de pérdida, proporcional a la suma de los cuadrados de los pesos de la red:

---

[20] Jason Brownlee. «A gentle introduction to early stopping to avoid overtraining neural networks». En: *Machine Learning Mastery* 7 (2018).

$$L_{total} = L_{original} + \lambda \sum_i w_i^2 \tag{1}$$

donde λ es el parámetro que controla la magnitud de la penalización. A diferencia de L1, la regularización L2 no lleva los coeficientes a cero, lo que contribuye a una mayor estabilidad numérica del modelo. En [21] se presenta una taxonomía de métodos de regularización en el aprendizaje profundo, destacando la efectividad de L2 en la mejora de la capacidad de generalización de las redes neuronales.

Aumento de datos (Data Augmentation): Es el proceso de aumentar artificialmente el tamaño y la diversidad del conjunto de datos de entrenamiento mediante la aplicación de transformaciones aleatorias, como rotación, escalado, volteo o recorte, a las imágenes de entrada. Esta técnica es especialmente útil en dominios donde obtener datos etiquetados es costoso, como en imágenes médicas.

3.4.4. APRENDIZAJE POR TRANSFERENCIA El aprendizaje por transferencia es un enfoque avanzado dentro del campo del aprendizaje automático que ha ganado considerable popularidad, especialmente en aplicaciones de aprendizaje profundo. En este método, un modelo previamente entrenado para realizar una tarea específica se reutiliza como punto de partida para entrenar un segundo modelo en una tarea relacionada. Este enfoque es comúnmente utilizado en arquitecturas de redes neuronales profundas, donde los pesos y parámetros de un modelo previamente entrenado se transfieren para ser utilizados en un nuevo contexto, lo que permite acelerar el proceso de entrenamiento y mejorar los resultados en tareas similares.

Modelo fuente: Es el modelo previamente entrenado que se selecciona de un con-

---

[21] Jan Kukačka, Vladimir Golkov y Daniel Cremers. «Regularization for deep learning: A taxonomy». En: *arXiv preprint arXiv:1710.10686* (2017).

junto de modelos candidatos. Este modelo ya ha sido entrenado en un conjunto de datos grande y general, como ImageNet, y ha aprendido a reconocer patrones y características en los datos. El modelo fuente proporciona una base sólida que el nuevo modelo puede aprovechar.

Modelo de reutilización: Una vez que se ha elegido el modelo fuente, este se utiliza como punto de partida para un nuevo modelo que debe ser entrenado en una tarea diferente pero relacionada. Dependiendo de los requisitos del problema y de las técnicas utilizadas, se puede optar por reutilizar todo el modelo o solo ciertas partes, como las capas de la red que han aprendido características generales (por ejemplo, bordes y texturas en el caso de imágenes).

Ajuste fino (Fine-tuning): Después de reutilizar el modelo entrenado, es posible que sea necesario ajustar o afinar ciertas partes del modelo para que se adapte mejor a los nuevos datos y tareas. Este proceso implica ajustar los pesos del modelo para que se especialice en las etiquetas de salida del nuevo conjunto de datos, lo cual se logra a través de una cantidad reducida de entrenamiento adicional.

El aprendizaje por transferencia ofrece múltiples ventajas significativas. Entre ellas destaca una reducción considerable del tiempo de entrenamiento, ya que al aprovechar modelos preentrenados que ya han aprendido patrones y características en conjuntos de datos extensos y generales, se evita entrenar desde cero, lo cual es especialmente valioso cuando se dispone de datos limitados o se busca reducir costos computacionales [22]. Además, esta técnica permite lograr una mayor precisión y eficiencia en tareas complejas, como clasificación de imágenes o procesamiento de lenguaje natural, mediante el ajuste selectivo de capas específicas en lugar de entrenar toda la red neuronal desde cero [23]. Por último, el aprendizaje por transferencia

---

[22] Chuanqi Tan et al. «A survey on deep transfer learning In International conference on artificial neural networks». En: *Cham, Switzerland: Springer* (2018), págs. 270-279.

[23] Fuzhen Zhuang et al. «A comprehensive survey on transfer learning». En: *Proceedings of the*

mejora el rendimiento con menos datos, pues al reutilizar conocimientos adquiridos previamente en conjuntos grandes y diversos, el modelo puede generalizar mejor incluso con volúmenes reducidos de datos, optimizando así su capacidad de predicción [24].

3.5. ARQUITECTURAS DE REDES NEURONALES CONVOLUCIONALES UTILIZADAS

La retinopatía diabética es una enfermedad ocular compleja y de diagnóstico desafiante, que requiere una alta precisión en la detección de cambios sutiles en las imágenes del fondo de ojo. Los modelos preentrenados, especialmente aquellos basados en arquitecturas profundas de redes neuronales convolucionales (CNN), han demostrado ser eficaces en tareas de procesamiento de imágenes. Dado que estos modelos han aprendido a identificar patrones de alto nivel en datos visuales durante su entrenamiento previo, pueden transferir ese conocimiento a la tarea de identificación de lesiones retinianas, como microaneurismas, exudados y hemorragias, mejorando la exactitud del diagnóstico.
A continuación se detallan las cuatro arquitecturas de CNN seleccionadas para este trabajo experimental, elegidas por sus características complementarias en términos de complejidad, eficiencia computacional y capacidad de generalización.

3.5.1. MOBILENETV2 MobileNetV2 es una red neuronal convolucional optimizada para dispositivos móviles y aplicaciones con recursos limitados. Fue presentada por Google en 2018 por Mark Sandler, Andrew Howard, Menglong Zhu y colabora-

---

IEEE 109.1 (2020), págs. 43-76.

[24] Karl Weiss, Taghi M Khoshgoftaar y DingDing Wang. «A survey of transfer learning». En: *Journal of Big data* 3.1 (2016), pág. 9.

dores [25]. MobileNetV2 está diseñada para ser eficiente tanto en términos de número de parámetros como en cálculos requeridos, lo que la hace adecuada para dispositivos con recursos limitados. La principal novedad de MobileNetV2 respecto a la versión anterior (MobileNetV1) es el uso de bloques residuales invertidos y cuellos de botella lineales, que permiten que la red mantenga un alto rendimiento mientras reduce la complejidad computacional.

Al igual que en MobileNetV1, esta red utiliza convoluciones separables en profundidad (depthwise separable convolutions). Este tipo de convolución separa el filtrado en dos pasos: una convolución de filtro por canal y una convolución 1×1 para combinar los resultados. Este enfoque reduce la cantidad de cálculos y parámetros respecto a las convoluciones tradicionales.

El corazón de esta arquitectura son los bloques residuales invertidos. En estos, las características primero se expanden a una dimensión mayor y posteriormente se procesan mediante una convolución separable en profundidad. Por último, las características se proyectan de nuevo a una dimensión más baja mediante una convolución de 1×1.

Otro aspecto único de MobileNetV2 es el uso de cuellos de botella lineales. Esto significa que después de la expansión de las características, la proyección de vuelta a un espacio de menor dimensión se realiza sin activaciones no lineales. Este enfoque ayuda a mantener la representación de características más eficiente, lo que se traduce en una mayor precisión y velocidad de la red en comparación con las redes tradicionales que usan activaciones no lineales después de la reducción de dimensiones.

---

[25] Mark Sandler et al. «Mobilenetv2: Inverted residuals and linear bottlenecks». En: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, págs. 4510-4520.

Figura 12. Arquitectura de MobileNetV2 mostrando bloques residuales invertidos

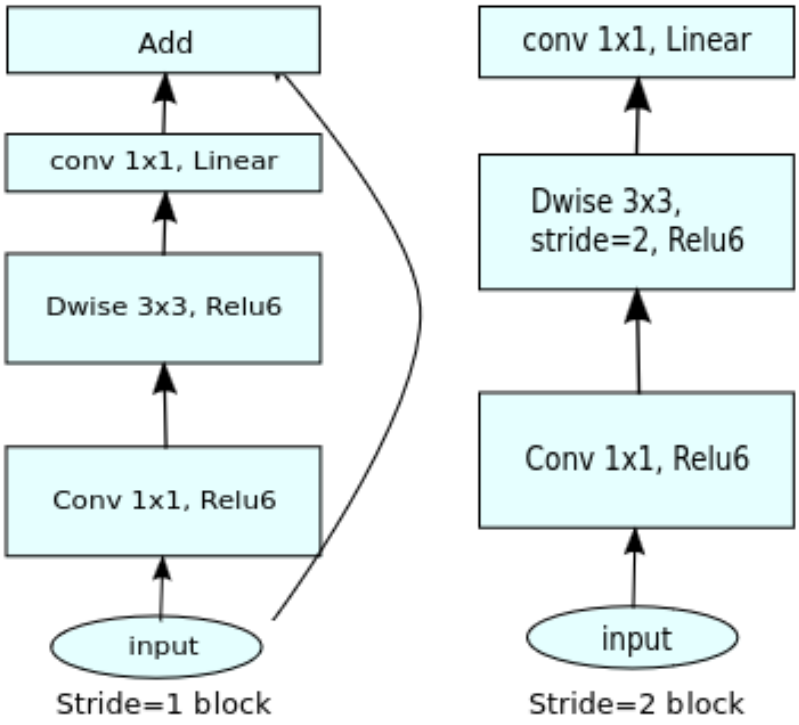

Fuente: Sandler et al. (2018)

En general, la arquitectura de MobileNetV2 se compone de una serie de bloques residuales invertidos que incluyen: expansión, la cual es una convolución de 1×1 que incrementa la dimensión de características; convolución por profundidad, que es una convolución separable en profundidad que aplica filtros de tamaño 3×3; y una proyección, que es una convolución de 1×1 que reduce la dimensión de las características a su tamaño original.

3.5.2. RESNET50V2 ResNet50V2 es una variante mejorada de la arquitectura ResNet (Red Residual) original, introducida con el objetivo de optimizar el flujo del gradiente durante el entrenamiento y, en consecuencia, mejorar la capacidad de

generalización y rendimiento. Esta versión fue presentada en el trabajo de Kaiming He, Xiangyu Zhang, Shaoqing Ren y Jian Sun [26].

El núcleo de ResNet, y por ende de ResNet50V2, son los llamados bloques residuales. Estos bloques incluyen conexiones de salto (skip connections) que permiten que el gradiente fluya más fácilmente hacia las capas iniciales durante el entrenamiento, mitigando el problema del desvanecimiento del gradiente en redes muy profundas. En la versión V2, la principal diferencia respecto a la original (V1) es que se reorganizan las operaciones en el bloque residual, además de que se incluyen mapeos de identidad mejorados y una mejor normalización [26].

Mientras que en ResNetV1 se utiliza una estructura del tipo convolución seguida de Batch Normalization y Activación ReLU, en ResNetV2 se antecede la normalización y la activación antes de la convolución, siguiendo un enfoque de pre-activación. Este cambio en el orden de las operaciones mejora el flujo de gradientes y facilita el entrenamiento de redes más profundas.

Figura 13. Arquitectura de ResNet50V2 con bloques residuales mejorados

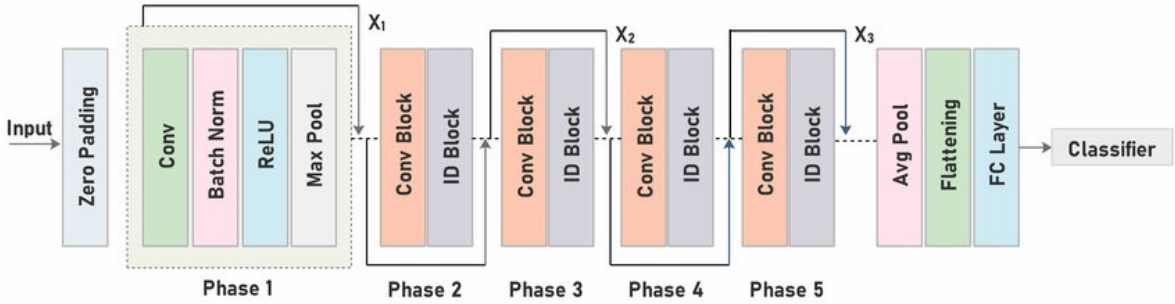

Fuente: He et al. (2016)

La arquitectura de esta red está compuesta por 50 capas profundas, organizadas

---

[26] Kaiming He et al. «Identity mappings in deep residual networks». En: *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14*. Springer. 2016, págs. 630-645.

en distintos bloques residuales con diferentes configuraciones de filtros y tamaños. Cada bloque residual en ResNet50V2 utiliza una estructura bottleneck, que consiste en tres capas convolucionales: 1×1, 3×3 y 1×1, lo que permite una reducción y expansión eficiente de las dimensiones de las características.

3.5.3. INCEPTIONV3 InceptionV3 es una arquitectura de red neuronal convolucional desarrollada para tareas de clasificación de imágenes, reconocida por su eficiencia y precisión. Es una evolución de las versiones anteriores de la familia Inception, introducida por Christian Szegedy y colaboradores de Google, introduciendo mejoras significativas en el procesamiento de características y la reducción de la complejidad computacional [27]. La arquitectura busca maximizar la eficiencia del modelo mediante la optimización de las operaciones convolucionales.

El componente principal de esta red son los módulos Inception. Estos combinan múltiples tipos de convoluciones y operaciones de pooling en paralelo dentro de una misma capa, lo que permite a la red capturar información a diferentes escalas y contextos espaciales de forma simultánea. En esta red, los módulos se optimizan mediante la factorización de convoluciones más grandes en secuencias de convoluciones más pequeñas y eficientes. Por ejemplo, una convolución de 5×5 puede descomponerse en dos convoluciones de 3×3, reduciendo así el número de parámetros y el costo computacional.

Además, InceptionV3 incorpora capas de reducción de dimensionalidad utilizando convoluciones 1×1. Estas capas ayudan a disminuir la dimensionalidad de las características antes de aplicar convoluciones más costosas, lo que mejora la eficiencia. También se utiliza la normalización por lotes después de cada convolución, lo que estabiliza y acelera el entrenamiento al normalizar las activaciones de cada capa.

---

[27] Christian Szegedy et al. «Rethinking the inception architecture for computer vision». En: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, págs. 2818-2826.

Otra de las características de la arquitectura de InceptionV3 es el uso de convoluciones asimétricas para capturar características espaciales de manera más eficiente. Estas convoluciones permiten que la red mantenga una alta capacidad de representación sin incrementar significativamente el número de parámetros. Además, para mejorar la propagación de la información de las etiquetas en las capas inferiores de la red y mitigar el problema del desvanecimiento del gradiente, InceptionV3 utiliza clasificadores auxiliares. Estos clasificadores adicionales actúan como regularizadores durante el entrenamiento, mejorando la convergencia y la precisión del modelo.

Figura 14. Arquitectura de InceptionV3 con módulos Inception paralelos

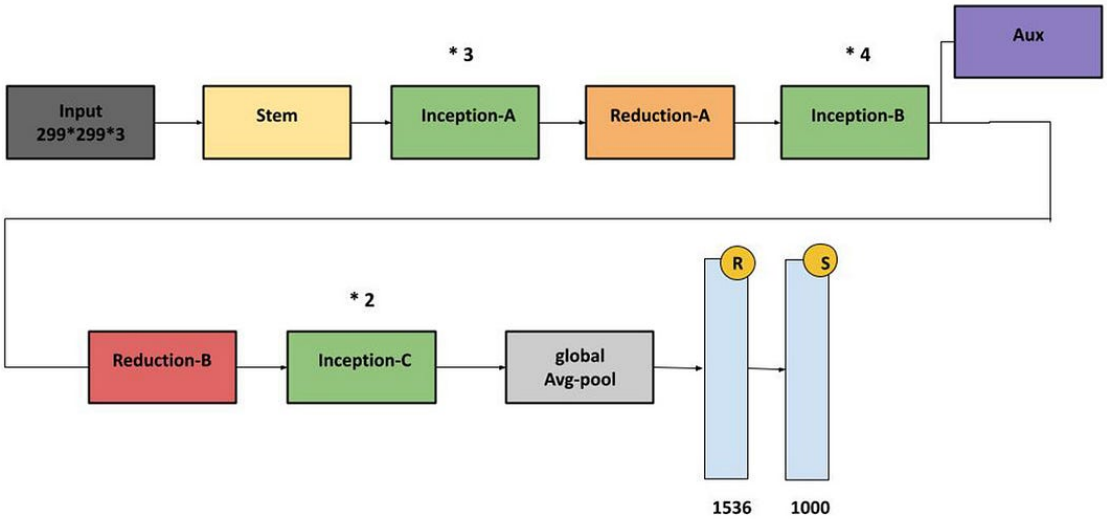

Fuente: Szegedy et al. (2016)

En general, la arquitectura de InceptionV3 está compuesta por una capa de entrada, seguida de módulos Inception con factorización de convoluciones y reducción de dimensionalidad. Por último se aplica una capa de Global Average Pooling seguida de capas completamente conectadas para la clasificación final.

3.5.4. VGG19 La arquitectura VGG19 pertenece a la familia de redes VGG (Visual Geometry Group) y fue desarrollada con el objetivo de investigar la relación entre la profundidad de las redes neuronales y su rendimiento. Esta red convolucional profunda fue introducida por Karen Simonyan y Andrew Zisserman de la Universidad de Oxford y diseñada específicamente para tareas de clasificación de imágenes. VGG19 se caracteriza por tener 19 capas en total: 16 de ellas son convolucionales y las 3 restantes son capas completamente conectadas. A pesar de su complejidad, la arquitectura de VGG19 se distingue por su simplicidad y su diseño sistemático, en el que se emplean filtros pequeños de 3×3 píxeles a lo largo de las capas convolucionales.

La estructura de VGG19 está organizada en bloques secuenciales de capas convolucionales, seguidos de capas de pooling y finalizando con capas totalmente conectadas. Cada bloque convolucional consta de entre 2 y 4 capas convolucionales, todas utilizando filtros de tamaño 3×3, con un stride de 1 y un padding de 1. Esta configuración permite mantener el tamaño espacial de las características durante el proceso de extracción, lo que ayuda a preservar la resolución de las imágenes a medida que se procesan a través de la red.

Uno de los aspectos clave de VGG19 es su uso de filtros pequeños (3×3), lo que facilita una mayor capacidad de aprendizaje y un control más fino sobre las características extraídas en cada capa. Además, la red utiliza capas de max pooling para reducir la dimensionalidad y la complejidad computacional sin perder información importante.

VGG19 ha sido una de las arquitecturas más influyentes en el campo de la visión por computadora debido a su rendimiento sobresaliente en tareas de clasificación de imágenes, como se demostró en la competencia ImageNet. La red también ha sido utilizada como modelo base en diversos problemas relacionados con el procesamiento de imágenes, adaptándose fácilmente a tareas como detección de objetos,

segmentación y, en el caso de la retinopatía diabética, clasificación de imágenes médicas.

Figura 15. Arquitectura de VGG19 con bloques convolucionales secuenciales

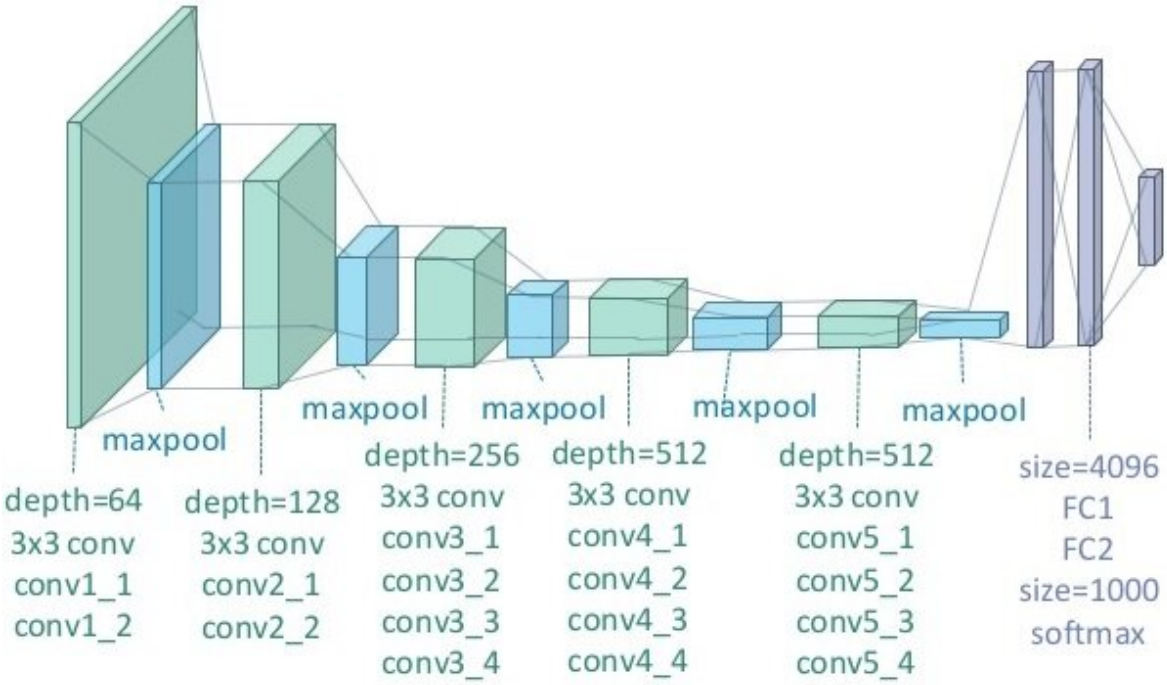

Fuente: Simonyan & Zisserman (2014)

3.5.5. Comparación de arquitecturas La Tabla 2 presenta una comparación cuantitativa de las cuatro arquitecturas seleccionadas, considerando aspectos clave para su aplicación en clasificación de imágenes médicas.

Tabla 2. Comparación de arquitecturas CNN utilizadas en este trabajo

Arquitectura	**Características distintivas**	**Capas**	**Parámetros**	**Ventaja principal**
MobileNetV2	Bloques residuales invertidos, convoluciones separables	53	$\sim$3.5M	Eficiencia computacional
ResNet50V2	Conexiones residuales con preactivación	50	$\sim$25M	Entrenamiento de redes profundas
InceptionV3	Módulos Inception paralelos, factorización	48	$\sim$24M	Captura multiescala
VGG19	Arquitectura simple y profunda con filtros 3x3	19	$\sim$144M	Simplicidad arquitectónica

Cada una de estas arquitecturas aporta características complementarias al estudio experimental. MobileNetV2 ofrece eficiencia computacional crucial para aplicaciones en recursos limitados; ResNet50V2 permite entrenar modelos muy profundos sin degradación de rendimiento; InceptionV3 captura información a múltiples escalas mediante sus módulos paralelos; y VGG19, a pesar de su mayor cantidad de parámetros, ofrece una arquitectura simple que ha demostrado efectividad en tareas de clasificación de imágenes médicas.

3.6. TRABAJOS PREVIOS

En los últimos años, las técnicas de aprendizaje profundo han demostrado un rendimiento excepcional en numerosas tareas que van desde el reconocimiento de objetos hasta el procesamiento del lenguaje natural. El uso de técnicas de aprendizaje profundo, específicamente redes neuronales convolucionales (CNN), ha demostrado resultados prometedores en la detección automática de RD a través del análisis de imágenes del fondo de ojo. Dentro de este contexto, se incluyen varios enfoques que han contribuido en este campo de investigación.

3.6.1. Enfoques con CNN personalizadas Este problema se ha abordado de distintas formas, planteándose distintas soluciones. En general, podemos ver en la literatura una preponderancia de la implementación de modelos previamente entrenados. Esto toma sentido cuando consideramos el costo de entrenamiento que tienen este tipo de modelos que se alimentan de cientos de miles de imágenes; solo pocos sectores de la industria tienen los recursos necesarios para llevar a cabo estos desarrollos. Muchos de los artículos recopilatorios encargados de comparar soluciones frente a la clasificación de la RD se encargan, en última instancia, de comparar la efectividad de distintos modelos preentrenados para la clasificación de la RD [28], donde se comparan ocho de los modelos preentrenados más utilizados desde 2011 hasta 2022.

En algunas investigaciones se observa un enfoque común: la personalización de un modelo de red neuronal convolucional (CNN) para abordar la detección automatizada de retinopatía diabética (RD). Esta estrategia implica modificar la arquitectura o los parámetros de un modelo CNN tradicional y mejorarlo en la tarea específi-

[28] Ruchika Bala, Arun Sharma y Nidhi Goel. «Comparative analysis of diabetic retinopathy classification approaches using machine learning and deep learning techniques». En: *Archives of Computational Methods in Engineering* 31.2 (2024), págs. 919-955.

ca de la detección de RD. En este contexto, se han explorado diversas estrategias para mejorar la precisión y eficiencia de la detección de RD a partir de imágenes del fondo de la retina. Por ejemplo, se han aplicado etapas de preprocesamiento como escalado, recorte y ecualización adaptativa del histograma con limitación de contraste (CLAHE) para mejorar la calidad de las imágenes [29].

Además, se han utilizado técnicas de aumento de datos mediante redes generativas adversariales (GAN) para enriquecer el conjunto de datos de entrenamiento. Otros trabajos han introducido variantes personalizadas de CNN, como la Red Neuronal Convolucional Dilatada Multiescala Híbrida en Cascada (HCMD-CNN) [30], que integra la Red de Atención Residual (RAN) y MobileNet, optimizando sus parámetros para lograr un mejor rendimiento en la detección de RD. Otros enfoques han empleado métodos de extracción de características mediante CNN, cuyas salidas se utilizan como entrada para diferentes clasificadores de aprendizaje automático [31] [32], como Support Vector Machine, AdaBoost, Naive Bayes, Random Forest y J48.

3.6.2. Enfoques con arquitecturas preentrenadas Últimamente se han desarrollado otras aproximaciones que aprovechan arquitecturas preentrenadas en el ámbito de la detección y clasificación de retinopatía diabética (RD) en imágenes

---

[29] AhlamAsadig Ali Tabtaba y Oguz Ata. «Diabetic retinopathy detection using developed hybrid cascaded multi-scale DCNN with hybrid heuristic strategy». En: *Biomedical Signal Processing and Control* 89 (2024), pág. 105718.

[30] S Gayathri, Varun P Gopi y Ponnusamy Palanisamy. «A lightweight CNN for Diabetic Retinopathy classification from fundus images». En: *Biomedical Signal Processing and Control* 62 (2020), pág. 102115.

[31] Yung-Hui Li et al. «Computer-assisted diagnosis for diabetic retinopathy based on fundus images using deep convolutional neural network». En: *Mobile Information Systems* 2019 (2019).

[32] S Gayathri, Varun P Gopi y P Palanisamy. «Diabetic retinopathy classification based on multipath CNN and machine learning classifiers». En: *Physical and engineering sciences in medicine* 44.3 (2021), págs. 639-653.

del fondo de ojo. Estos enfoques abarcan una variedad de modelos de aprendizaje profundo, tales como VGG16, InceptionResNetv2, Inceptionv3, DenseNet121, MobileNetV2, Xception y YOLOv3, los cuales se han utilizado para extraer características y llevar a cabo tareas de clasificación y detección.

Por ejemplo, un estudio implementó una red neuronal convolucional (CNN) utilizando VGG16 para la extracción de características de imágenes de retina y la técnica de sobremuestreo de minoría sintética (SMOTE) para manejar el desequilibrio de clases en el conjunto de datos [33], logrando una precisión del 93.94 % durante la fase de entrenamiento y del 88.19 % durante la validación.

Otro enfoque consistió en dos modelos basados en aprendizaje profundo: CNN512, que clasificó imágenes completas en estadios de RD con una precisión del 88.6 %, y un modelo YOLOv3 adaptado para detectar y localizar lesiones de DR, alcanzando un mAP de 0.216 en la localización de lesiones [34]. Estos modelos se fusionaron para clasificar imágenes de RD y localizar lesiones, obteniendo una precisión del 89 % con sensibilidad del 89 % y especificidad del 97.3 %.

Además, se ha explorado el aprendizaje por transferencia utilizando modelos preexistentes como InceptionResNetv2 e Inceptionv3, junto con un nuevo modelo DiaCNN, para la clasificación de enfermedades oculares en el conjunto de datos ODIR [35]. Estos modelos alcanzaron impresionantes niveles de precisión, llegando hasta el 99.7 % en algunas pruebas.

---

[33] Hiri Mustafa et al. «Rapid detection of diabetic retinopathy in retinal images: a new approach using transfer learning and synthetic minority oversampling technique.» En: *International Journal of Electrical & Computer Engineering (2088-8708)* 14.1 (2024).

[34] Wejdan L Alyoubi, Maysoon F Abulkhair y Wafaa M Shalash. «Diabetic retinopathy fundus image classification and lesions localization system using deep learning». En: *Sensors* 21.11 (2021), pág. 3704.

[35] Mohamed R Shoaib et al. «Deep learning innovations in diagnosing diabetic retinopathy: The potential of transfer learning and the DiaCNN model». En: *Computers in Biology and Medicine* 169 (2024), pág. 107834.

Asimismo, se ha abordado la detección automática de vasos sanguíneos retinianos utilizando modelos como ResNet34, InceptionV3 y VGG16, y se han propuesto enfoques multinivel [36] para mejorar la clasificación binaria y multiclase de imágenes de RD [37], logrando una precisión del 96.50 % en la clasificación binaria y una kappa ponderada cuadrática del 93.00 % en la clasificación por etapas. Estos avances muestran mejoras significativas en precisión y generalización, con resultados que superan a los métodos tradicionales y a los trabajos previos en la literatura.

3.6.3. Enfoques con modificaciones arquitectónicas innovadoras Por otra parte, existen otros trabajos en la literatura que han optado por realizar modificaciones sustanciales a las arquitecturas CNN para obtener un mejor desempeño. Se han propuesto varias técnicas innovadoras para mejorar el rendimiento y la eficiencia del aprendizaje profundo en la detección y clasificación de retinopatía diabética (RD) [38].

Un estudio aborda el aprendizaje profundo distribuido (DDL) para entrenar modelos de DL de manera rápida, utilizando dos GPU y analizando el rendimiento del canal de paralelismo en DDL, logrando una puntuación F1 de validación de 0.834 en la clasificación de RD. Otro enfoque se centra en la diversidad de los conjuntos de datos de entrenamiento mediante la manipulación de datos de entrada, mejorando

---

[36] Tawfiq Beghriche et al. «A multi-level fine-tuned deep learning based approach for binary classification of diabetic retinopathy». En: *Chemometrics and Intelligent Laboratory Systems* 237 (2023), pág. 104820.

[37] Richa Vij y Sakshi Arora. «A hybrid evolutionary weighted ensemble of deep transfer learning models for retinal vessel segmentation and diabetic retinopathy detection». En: *Computers and Electrical Engineering* 115 (2024), pág. 109107.

[38] Mahesh S Patil y Satyadhyan Chickerur. «Study of data and model parallelism in distributed deep learning for diabetic retinopathy classification». En: *Procedia Computer Science* 218 (2023), págs. 2253-2263.

así el rendimiento de la clasificación [39].

Además, se propone un enfoque bioinspirado en la metaplasticidad sináptica, que se incorpora en redes neuronales convolucionales para fortalecer las ocurrencias menos comunes durante el aprendizaje [40]. Este método mejora tanto la tasa de aprendizaje como la precisión, superando a otros métodos de la literatura actual incluso con conjuntos de datos más pequeños, con resultados destacados en la arquitectura InceptionV3.

3.6.4. Limitaciones y brechas de investigación A pesar del avance significativo en el uso de técnicas de aprendizaje profundo para la detección de RD a partir de imágenes del fondo de ojo, aún existen algunas limitaciones que deben abordarse para garantizar su aplicabilidad en el mundo real y su adopción en la práctica clínica. La mayoría de los modelos actuales se entrenan con conjuntos de datos limitados y específicos, lo que limita su capacidad para generalizar a escenarios del mundo real con mayor variabilidad en las imágenes del fondo de ojo. En muchos conjuntos de datos, las imágenes con RD representan una pequeña proporción en comparación con las imágenes normales. Este desequilibrio de clases puede afectar el rendimiento del modelo, sesgando la clasificación hacia la clase mayoritaria.

Algunos estudios se enfocan únicamente en la detección de la presencia o ausencia de RD, sin considerar la clasificación de su gravedad en estadios tempranos, moderados o severos, lo cual es crucial para la toma de decisiones oportunas en el manejo de la enfermedad. El ruido, la iluminación inconsistente y el bajo contraste en las imágenes del fondo de ojo pueden afectar significativamente la precisión de

---

[39] Shashank Anand Patil et al. «Pipeline Parallelism in Distributed Deep Learning for Diabetic Retinopathy Classification». En: *Procedia Computer Science* 215 (2022), págs. 393-402.

[40] Víctor Vives-Boix y Daniel Ruiz-Fernández. «Diabetic retinopathy detection through convolutional neural networks with synaptic metaplasticity». En: *Computer Methods and Programs in Biomedicine* 206 (2021), pág. 106094.

la clasificación. La implementación de técnicas de preprocesamiento de imágenes robustas es fundamental para mejorar el rendimiento de los modelos.
Pocos trabajos han explorado sistemáticamente el efecto del procesamiento de canales de color individuales (rojo, verde, azul) en el desempeño de clasificación de RD, a pesar de que diferentes canales pueden resaltar lesiones específicas. Además, existe una escasez de validación externa rigurosa en múltiples datasets con características de adquisición diferentes, lo cual es esencial para demostrar la capacidad de generalización de los modelos.

3.6.5. Contribución del presente trabajo El empleo de algoritmos de aprendizaje profundo en la detección de RD a partir de imágenes del fondo de ojo presenta un gran potencial para mejorar la accesibilidad, la precisión y la eficiencia del tamizaje de esta enfermedad. Sin embargo, es necesario abordar las limitaciones actuales relacionadas con la generalización de los modelos, el desequilibrio de clases, la clasificación de la gravedad y el preprocesamiento de imágenes para garantizar su aplicabilidad en entornos clínicos reales y su adopción como una herramienta confiable para el diagnóstico y seguimiento de la RD.
El presente trabajo contribuye al estado del arte en los siguientes aspectos:

- **Análisis sistemático de canales de color:** Evaluación comparativa del desempeño de modelos procesando imágenes RGB completas versus canales individuales (rojo, verde, azul), identificando el canal más efectivo para clasificación multiclase.

- **Comparación controlada de arquitecturas:** Evaluación sistemática de cuatro arquitecturas CNN preentrenadas (MobileNetV2, ResNet50V2, InceptionV3, VGG19) bajo condiciones experimentales idénticas.

- **Validación externa rigurosa:** Evaluación del mejor modelo en tres datasets

externos independientes (MESSIDOR-2, IDRiD, FOSCAL) con diferentes características de adquisición y distribución de clases.

- **Combinación de técnicas de regularización:** Integración de bloques Multi-Head Attention, capas GaussianNoise y técnicas tradicionales (Dropout, L2, early stopping) para mejorar generalización.
- **Enfoque dual de clasificación:** Desarrollo y evaluación tanto de clasificadores binarios (optimizados para tamizaje) como multiclase (para gradación clínica), permitiendo su aplicación en diferentes escenarios clínicos.

Estas contribuciones llenan vacíos identificados en la literatura y proporcionan evidencia empírica sobre decisiones de diseño relevantes para la implementación de sistemas automatizados de detección de retinopatía diabética.

Conclusión del capítulo

Este capítulo ha presentado los fundamentos teóricos necesarios para comprender el desarrollo y evaluación de sistemas automatizados de detección de retinopatía diabética mediante aprendizaje profundo. Se han cubierto desde los aspectos clínicos de la enfermedad y las características de las imágenes de fondo de ojo, hasta los conceptos fundamentales de inteligencia artificial, aprendizaje automático y redes neuronales convolucionales.

La revisión de arquitecturas CNN preentrenadas (MobileNetV2, ResNet50V2, InceptionV3, VGG19) ha proporcionado el contexto necesario para comprender las decisiones de diseño del presente trabajo. Asimismo, la revisión del estado del arte ha identificado los enfoques existentes, sus logros y sus limitaciones, justificando las contribuciones específicas que este trabajo aporta al campo.

En el siguiente capítulo se describirá la metodología empleada para abordar el problema de detección de retinopatía diabética, detallando los procesos de recopilación

y preprocesamiento de datos, las configuraciones experimentales implementadas, y las técnicas de evaluación utilizadas para validar el desempeño de los modelos desarrollados.

4. METODOLOGÍA

Este capítulo describe el procedimiento metodológico seguido para desarrollar e implementar los modelos de clasificación de retinopatía diabética basados en aprendizaje profundo. La metodología se estructura en cinco etapas principales que abordan los objetivos específicos OE2 a OE8 planteados en el Capítulo 2: primero, la recopilación y caracterización de conjuntos de datos de imágenes de fondo de ojo (OE2); segundo, el preprocesamiento y balanceo de datos para optimizar la calidad del conjunto de entrenamiento (OE3); tercero, la selección de tecnologías y herramientas de desarrollo; cuarto, la configuración e implementación de las arquitecturas CNN con técnicas de regularización (OE4, OE5, OE6, OE7); y finalmente, la definición de métricas de evaluación para validar el desempeño de los modelos (OE8). La Figura 16 presenta un diagrama que sintetiza el flujo completo del proceso metodológico implementado.

Figura 16. Estructura metodológica propuesta para la clasificación de retinopatía diabética mediante aprendizaje profundo

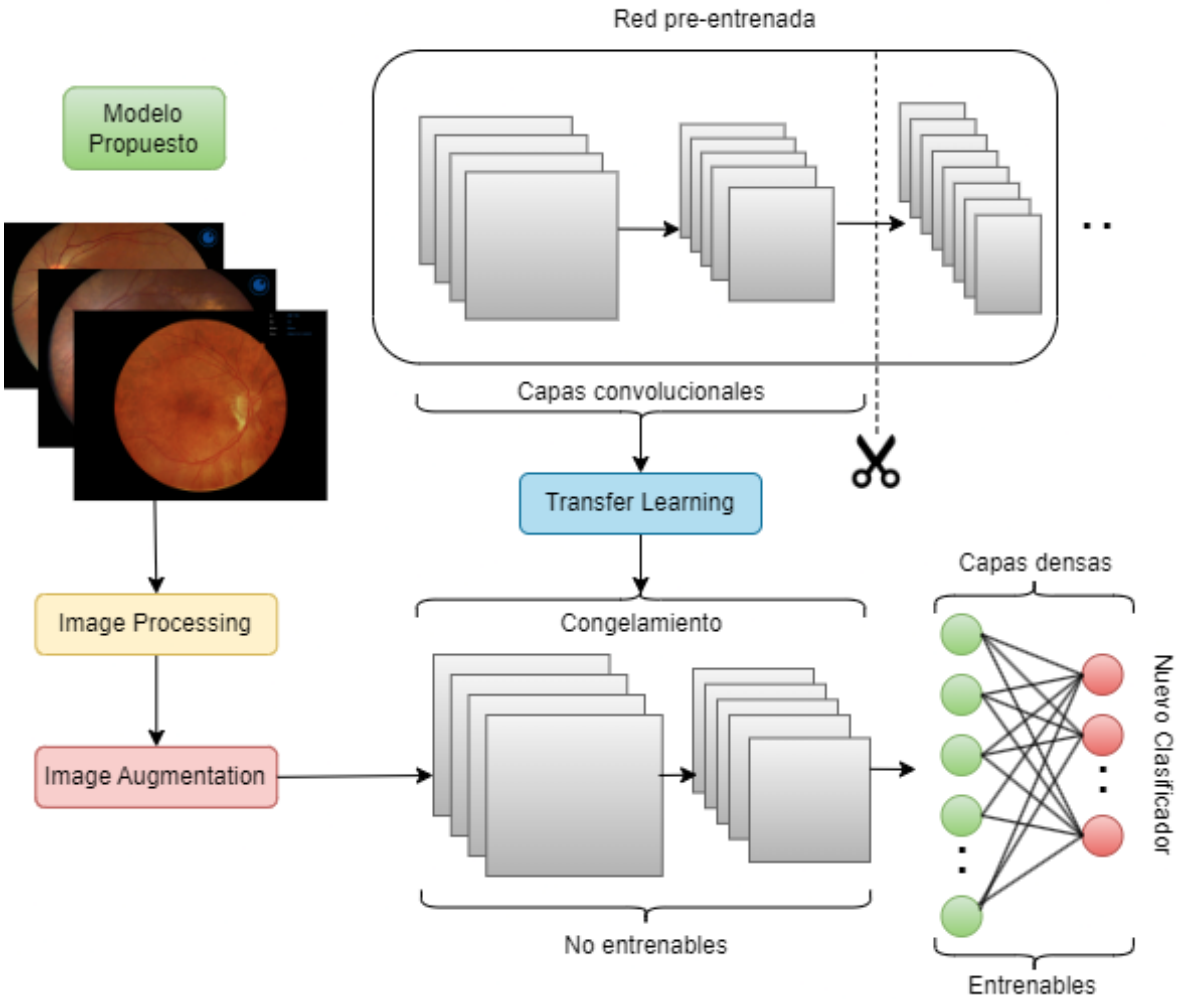

Fuente: Elaboración propia

4.1. CONJUNTOS DE DATOS

Una etapa clave en la construcción de una red neuronal convolucional (CNN) es la recopilación de datos, ya que el rendimiento del modelo depende en gran medida tanto de la calidad como de la diversidad del conjunto utilizado. Para que el entrenamiento sea efectivo, las imágenes deben reflejar con precisión las distintas con-

diciones del problema y pueden obtenerse a partir de repositorios públicos, fuentes en línea o mediante técnicas de generación artificial. Es esencial que cada imagen esté correctamente clasificada según corresponda, ya que una mala etiquetación puede afectar negativamente el aprendizaje del modelo. Por ello, es importante realizar una curaduría rigurosa del dataset, priorizando imágenes representativas y bien definidas.

En el desarrollo de este proyecto se utilizaron distintos conjuntos de datos para garantizar la robustez y generalización del modelo. Inicialmente se exploraron datasets disponibles en repositorios públicos, junto con un conjunto de datos de propiedad privada. La fase experimental inicial se llevó a cabo con el dataset de Kaggle debido a su gran volumen de imágenes. Posteriormente se utilizaron los datasets públicos MESSIDOR-2, IDRiD y uno privado denominado FOSCAL para evaluar la capacidad de generalización del modelo final mediante validación externa.

4.1.1. Dataset de Kaggle (Entrenamiento) Es el dataset principal que se utilizó para entrenar y validar los modelos experimentales. Cuenta con un amplio conjunto de datos compuesto por imágenes de retina en alta resolución, obtenidas a partir del repositorio *Diabetic Retinopathy Detection 2015*, disponible en la plataforma Kaggle. Las imágenes fueron capturadas bajo diversas condiciones y con distintos tipos de cámaras, lo que introduce variabilidad en aspectos como la resolución, la iluminación y la orientación.

Cada registro corresponde a un paciente, identificándose ambos ojos mediante un nombre de archivo que incluye el número de paciente seguido de ïzquierda.º "derecha"(por ejemplo: `1_izquierda.jpg`). Cada imagen fue evaluada por un especialista clínico, quien asignó un grado de severidad de retinopatía diabética utilizando una escala ordinal de 0 a 4, donde:

0. Sin retinopatía diabética

1. Leve
2. Moderada
3. Severa
4. Retinopatía diabética proliferativa

La naturaleza heterogénea del conjunto se evidencia en las diferencias anatómicas y de orientación presentes en las imágenes: algunas muestran la retina con una disposición convencional (mácula a la izquierda y nervio óptico a la derecha en el caso del ojo derecho), mientras que otras presentan una orientación invertida, similar a la observada a través de un microscopio durante un examen clínico. La orientación puede determinarse a partir de la posición relativa entre la mácula y el nervio óptico, así como por la presencia de muescas laterales en la imagen.
Es importante señalar que el conjunto contiene ruido, tanto en las imágenes (como artefactos, desenfoque, subexposición o sobreexposición), como en las etiquetas, debido a la subjetividad inherente a la evaluación clínica. Por esta razón, uno de los retos principales de este estudio es desarrollar algoritmos robustos, capaces de enfrentar dicha variabilidad y el ruido presente en los datos, asegurando un desempeño confiable en escenarios reales de aplicación.

4.1.2. MESSIDOR-2 (Validación externa) Es una base de datos de imágenes de fondo de ojo diseñada para evaluar algoritmos de detección de retinopatía diabética, particularmente para la clasificación de casos referibles. Contiene un total de 1,748 imágenes correspondientes a 874 exámenes de pacientes, capturadas con cámaras no midriáticas Topcon TRC NW6, NW7 y Nidek AFC-210, con un campo de visión de 45°. Las imágenes presentan resoluciones variables, típicamente entre 1440×960 y 2304×1536 píxeles, y están centradas en la mácula.

Este conjunto cuenta con: etiquetas de gradación de retinopatía diabética (RD) en una escala de 0 a 3; etiquetas de edema macular, validadas por especialistas; y metadatos como el diámetro pupilar y la calidad técnica de cada imagen. Gracias a su calidad, volumen y amplia adopción en la comunidad científica, MESSIDOR-2 es ampliamente empleado como benchmark para evaluar el rendimiento y la generalización de modelos de clasificación de RD, especialmente en escenarios de validación externa y estudios comparativos.

4.1.3. IDRiD (Validación externa) El *Indian Diabetic Retinopathy Image Dataset* contiene un total de 516 imágenes de retina en alta resolución (4288×2848 píxeles), capturadas con una cámara Kowa VX-10α con un campo de visión de 50°, centradas en la mácula. Las imágenes provienen de pacientes del Aravind Eye Hospital en India y están acompañadas de anotaciones detalladas realizadas por expertos clínicos.

Este conjunto incluye: etiquetas de clasificación de severidad de RD; segmentaciones a nivel de píxel para lesiones específicas como microaneurismas, hemorragias, exudados duros y blandos; y segmentaciones de estructuras anatómicas como la fóvea y el disco óptico. El dataset se divide en un conjunto de entrenamiento con 413 imágenes y un conjunto de prueba con 103 imágenes, lo que lo hace especialmente útil tanto para tareas de clasificación como de segmentación.

4.1.4. FOSCAL (Validación externa) El dataset FOSCAL está compuesto por 1,538 imágenes de fondo de ojo, obtenidas gracias al Centro de Prevención y Consultoría en Glaucoma de Bucaramanga (Fundación Oftalmológica de Santander - FOSCAL). Las imágenes estaban acompañadas de un archivo plano que detalla las anomalías presentes, incluyendo el nivel de retinopatía diabética (RD), lo que permitió organizarlas con sus respectivas etiquetas.

El proceso de etiquetado fue realizado por especialistas médicos mediante una pla-

taforma web diseñada específicamente para la lectura y tamizaje. Esta plataforma incluía funcionalidades para descartar imágenes de baja calidad o no evaluables, garantizando así la confiabilidad de los datos. Este dataset representa condiciones clínicas locales y fue utilizado como validación externa para evaluar el desempeño del modelo en un contexto colombiano específico.

4.1.5. Distribución de datos La Tabla 3 presenta la distribución de imágenes por clase de severidad en cada uno de los datasets utilizados, mostrando la variabilidad en la distribución de clases entre diferentes fuentes de datos.

Tabla 3. Distribución de imágenes por clase de severidad de retinopatía diabética en los distintos datasets

Dataset	No RD	Leve	Moderada	Severa	Prolif.	Total	Uso
Kaggle	25,810	2,443	5,292	873	703	35,121	Entrenamiento
MESSIDOR-2	1,017	270	347	114	—	1,748	Validación ext.
IDRiD	213	117	54	56	76	516	Validación ext.
FOSCAL	302	34	23	40	16	415	Validación ext.

4.1.6. División de datos para entrenamiento y validación El dataset de Kaggle se dividió en tres subconjuntos siguiendo una estrategia de partición estratificada para mantener la proporción de clases en cada subconjunto:

- **Conjunto de entrenamiento (70 %):** 24,585 imágenes utilizadas para el ajuste de pesos del modelo.
- **Conjunto de validación (15 %):** 5,268 imágenes utilizadas para la optimiza-

ción de hiperparámetros y detección de sobreajuste durante el entrenamiento.

- **Conjunto de prueba interno (15 %):** 5,268 imágenes reservadas para la evaluación final del modelo antes de validación externa.

Esta división se implementó utilizando la función `train_test_split` de scikit-learn con el parámetro `stratify` para asegurar que la distribución de clases se mantuviera consistente en todos los subconjuntos.

4.2. PREPROCESAMIENTO DE LAS IMÁGENES

Durante el análisis exhaustivo del conjunto de datos, se identificaron varios problemas que afectan negativamente el desempeño de los modelos. Entre los principales desafíos se encontraron una cantidad significativa de imágenes dañadas o de baja calidad, las cuales dificultan el proceso de aprendizaje del modelo, así como un notable desbalance entre las clases, especialmente por la predominancia de la clase correspondiente a pacientes sanos. Este desbalance puede llevar al modelo a sesgar sus predicciones hacia la clase mayoritaria, reduciendo su capacidad de generalización. Por ello fue necesario aplicar estrategias específicas de limpieza, filtrado y balanceo, orientadas a mejorar la calidad de los datos sin eliminar muestras valiosas ni conservar imágenes que pudieran perjudicar el entrenamiento.

4.2.1. Depuración de imágenes defectuosas Durante el proceso de exploración y limpieza del conjunto de datos, se identificó un número considerable de imágenes que presentaban problemas severos de iluminación: algunas eran casi completamente oscuras y otras excesivamente brillantes. En ambas situaciones resultaba imposible distinguir adecuadamente la circunferencia del globo ocular o las estructuras internas relevantes para la detección de retinopatía diabética. A pesar de ello, estas imágenes estaban etiquetadas con niveles de severidad entre 0 y 4,

lo que indicaba que habían sido consideradas válidas en el conjunto original. No obstante, su falta de información visual útil no solo limita su valor diagnóstico, sino que también puede introducir ruido y dificultar el proceso de aprendizaje del modelo. Para abordar este problema, se diseñó un procedimiento automático de limpieza basado en el análisis del brillo promedio de las imágenes. Esta estrategia consistió en convertir cada imagen a escala de grises y calcular su luminosidad media. Si el valor promedio se encontraba por debajo de un umbral establecido para imágenes demasiado oscuras ($\mu_{brillo} < 10$) o por encima de un umbral para imágenes excesivamente brillantes ($\mu_{brillo} > 245$), la imagen se consideraba no apta para el entrenamiento. Aquellas que cumplían con estos criterios eran automáticamente separadas del conjunto principal y movidas a una carpeta de exclusión. Este proceso se implementó utilizando OpenCV y NumPy en Python, y permitió filtrar de manera eficiente las imágenes que no aportan información significativa.

4.2.2. Balanceo de clases El conjunto de datos original presenta un marcado desbalance entre las clases, lo cual representa un desafío importante para la construcción de clasificadores. En particular, y en el escenario multiclase, la clase 0 (pacientes sanos) representa aproximadamente el 73 % del total de muestras, mientras que la clase 4 (retinopatía diabética proliferativa), la forma más severa de la enfermedad, apenas alcanza el 2 %. Esta relación —muy superior a 4:1 en el caso multiclase— tiende a sesgar el aprendizaje hacia la clase mayoritaria y reduce la capacidad del modelo para detectar correctamente las clases menos representadas. Este efecto del desbalance en el rendimiento de clasificadores ha sido ampliamente

documentado en la literatura sobre aprendizaje con datos desbalanceados [41] [42].
En general, para mitigar los problemas derivados del desbalance, se aplicaron dos estrategias principales: una reducción de la clase 0 y un aumento artificial de las clases minoritarias. En el escenario multiclase, un muestreo aleatorio directo sobre la clase 0 no resultó óptimo, ya que esta contenía un número considerable de imágenes con ruido o baja calidad. Para evitar descartar ejemplos útiles y conservar otros potencialmente perjudiciales, se realizó primero una limpieza manual, con lo que se obtuvo una base más depurada que facilitó el posterior balanceo entre las cinco categorías.
En el clasificador binario, en cambio, el enfoque consistió en agrupar todas las categorías con retinopatía en una sola clase (RD) frente a las imágenes sin enfermedad (No RD). Tras esta unificación, la clase No RD seguía siendo claramente mayoritaria, por lo que se aplicó un submuestreo aleatorio hasta lograr una proporción cercana al 50:50 entre ambas clases. Esta estrategia garantizó un entrenamiento más equilibrado y redujo el riesgo de sesgo hacia la clase mayoritaria.

4.2.3. Aumento de datos El aumento de datos, aunque es una técnica común y poderosa dentro del aprendizaje profundo, debe ser aplicado con cautela, especialmente cuando se trabaja con modelos preentrenados. Estos modelos, al contar con una gran cantidad de parámetros ajustables, pueden ser más propensos al sobreajuste si se les expone a transformaciones que alteran excesivamente la naturaleza de los datos originales.
Para mitigar este riesgo, se priorizó el uso de transformaciones que introducen varia-

---

[41] Justin M Johnson y Taghi M Khoshgoftaar. «Survey on deep learning with class imbalance». En: *Journal of big data* 6.1 (2019), págs. 1-54.

[42] Mubarak Taiwo Mustapha y Dilber Uzun Ozsahin. «Class imbalance and its impact on predictive models for binary classification of disease: a comparative analysis». En: *Artificial Intelligence and Image Processing in Medical Imaging*. Elsevier, 2024, págs. 389-408.

bilidad sin modificar la estructura fundamental de la imagen. Estas técnicas preservan la integridad visual de las retinografías al tiempo que enriquecen la diversidad del conjunto de entrenamiento [43]. Se implementó un conjunto de transformaciones geométricas moderadas utilizando la clase `ImageDataGenerator` de Keras, que permitió generar nuevas muestras a partir de imágenes existentes de forma controlada. La Tabla 4 detalla las transformaciones aplicadas y sus parámetros específicos:

Tabla 4. Configuración de transformaciones de aumento de datos aplicadas

Transformación	**Descripción**	**Parámetro**
Rotación	Rotación aleatoria de la imagen	$\pm 10°$
Zoom	Acercamiento/alejamiento aleatorio	$\pm 5\,\%$
Desplazamiento horizontal	Traslación horizontal de la imagen	$\pm 5\,\%$
Desplazamiento vertical	Traslación vertical de la imagen	$\pm 5\,\%$
Volteo horizontal	Reflexión horizontal (flip)	Probabilidad 0.5
Modo de relleno	Interpolación para píxeles faltantes	Nearest

Estas operaciones fueron aplicadas únicamente a las clases minoritarias (1, 2, 3, 4) con el objetivo de equilibrar la distribución del conjunto de datos. Al concluir los procesos de limpieza y aumento de datos, se obtuvo un conjunto de datos significativamente más robusto, con menos información que pudiera interferir con el aprendizaje del modelo. Además, se ha logrado un balance adecuado entre las clases, lo que

[43] Connor Shorten y Taghi M Khoshgoftaar. «A survey on image data augmentation for deep learning». En: *Journal of big data* 6.1 (2019), págs. 1-48.

favorece una mayor capacidad de generalización en el modelo. La Tabla 5 muestra la distribución final del dataset optimizado.

Tabla 5. Distribución de clases en el conjunto de datos aumentado y balanceado

Nivel de RD	Etiqueta	Cantidad de Imágenes	Porcentaje (%)
0	No RD	7,000	23.33
1	Leve	6,998	23.33
2	Moderada	6,000	20.00
3	Severa	4,996	16.65
4	Proliferativa	4,999	16.66
Total		**29,993**	**100.00**

4.2.4. Filtrado y realce de características Para reducir la variabilidad entre las imágenes de fondo de ojo asociada a diferencias en iluminación, resolución de las cámaras y condiciones de captura, se implementó una técnica de preprocesamiento basada en la metodología de Ben Graham (2015) [44]. Este proceso, ilustrado en la Figura 17, consta de tres etapas secuenciales diseñadas para homogeneizar las características visuales de las imágenes y priorizar las regiones anatómicas relevantes.

[44] Ben Graham. *Kaggle Diabetic Retinopathy Detection Competition Report*. University of Warwick. 2nd place solution report. 2015.

Figura 17. Pseudocódigo del algoritmo de preprocesamiento de Ben Graham

Algorithm 1 OpenCV Python code to preprocess the images.

```
import cv2, glob, numpy
def scaleRadius(img,scale):
    x=img[img.shape[0]/2,:,:].sum(1)
    r=(x>x.mean()/10).sum()/2
    s=scale*1.0/r
    return cv2.resize(img,(0,0),fx=s,fy=s)

scale=300
for f in glob.glob("train/*.jpeg")+glob.glob("test/*.jpeg"):
   try:
        a=cv2.imread(f)
        #scale img to a given radius
        a=scaleRadius(a,scale)
        #subtract local mean color
        a=cv2.addWeighted(a,                                    4,
                          cv2.GaussianBlur(a,(0,0),scale/30),-4,
                          128)
        #remove outer 10%
        b=numpy.zeros(a.shape)
        cv2.circle(b,(a.shape[1]/2,a.shape[0]/2),
                   int(scale*0.9),(1,1,1),-1,8,0)
        a=a*b+128*(1-b)
        cv2.imwrite(str(scale)+"_"+f,a)
    except:
        print f
```

Fuente: Adaptado de Graham (2015)

Inicialmente las imágenes se redimensionaron para estandarizar el radio del área de interés en 300 o 500 píxeles, según el caso. Este paso no solo normaliza la escala entre muestras, sino que también optimiza el uso de recursos computacionales en etapas posteriores. A continuación se aplicó una normalización del color mediante la sustracción del promedio local de intensidad —calculado con un filtro gaussiano— y su remapeo a un nivel de gris medio (50 %). Esta corrección mitiga las variaciones de brillo y contraste, frecuentes en entornos clínicos reales.

Matemáticamente, la normalización de color se expresa como:

$$I_{norm}(x,y) = \frac{I(x,y) - I_{local_mean}(x,y)}{\sigma_{local}(x,y) + \epsilon} \cdot k + 128 \tag{2}$$

donde $I(x,y)$ es la intensidad del píxel original, $I_{local_mean}(x,y)$ es la media local calculada con filtro gaussiano, $\sigma_{local}(x,y)$ es la desviación estándar local, ϵ es una constante pequeña para evitar división por cero, y k es un factor de escalado.

Por último se enmascaró el 10 % periférico de cada imagen mediante una máscara circular, eliminando así artefactos y regiones no informativas mientras se enfoca el análisis en la zona central de la retina. De este modo, el algoritmo garantiza que las imágenes procesadas presentan una mayor consistencia, lo cual resulta fundamental para etapas posteriores de análisis y entrenamiento de modelos. La Figura 18 muestra la implementación paso a paso del procedimiento, donde se observa el escalado, la normalización del color y el recorte aplicados a cada imagen.

Figura 18. Ejemplo visual del proceso de preprocesamiento aplicado a una imagen de fondo de ojo

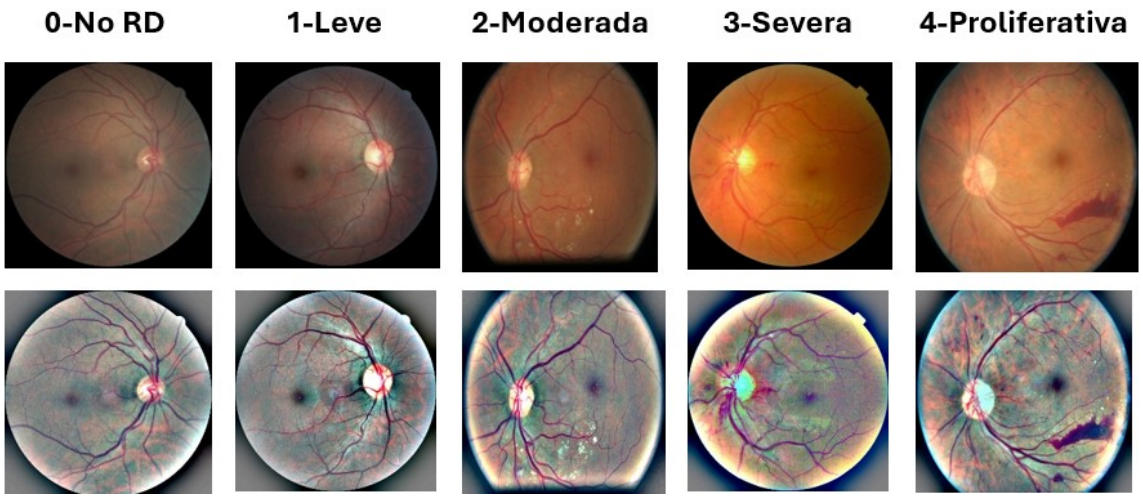

Fuente: Elaboración propia

4.3. TECNOLOGÍAS EMPLEADAS EN EL DESARROLLO

4.3.1. Lenguaje de programación En el desarrollo de este trabajo de investigación, se consideraron algunos lenguajes de programación para la implementación de las CNNs, cada uno con aspectos particulares en el ámbito del procesamiento de imágenes y el aprendizaje profundo. En primer lugar se tomó en cuenta R, un lenguaje con una gran variedad de paquetes especializados en modelos estadísticos y aprendizaje automático. Sin embargo, su desempeño en tareas de deep learning es limitado en comparación con otros lenguajes.

Se consideró también C++, un lenguaje altamente eficiente y optimizado, utilizado en aplicaciones donde el rendimiento es crítico. No obstante, su curva de aprendizaje es más pronunciada y el desarrollo de modelos de aprendizaje profundo en este lenguaje requiere una mayor cantidad de código en comparación con lenguajes de alto nivel.

De este modo, se optó por Python debido a su sintaxis clara y legible que facilita la implementación de modelos complejos. Además, cuenta con una amplia comunidad de desarrolladores y científicos que contribuyen con documentación, foros de discusión y soluciones a problemas frecuentes, lo que resulta en un entorno de desarrollo altamente colaborativo. Python cuenta con un ecosistema robusto de herramientas, incluyendo librerías como NumPy, Pandas y Matplotlib, que son fundamentales para la manipulación y análisis de datos, así como para la visualización de resultados. Asimismo, su compatibilidad con aceleradores de hardware, como GPUs y TPUs, permite el entrenamiento eficiente de modelos a gran escala, reduciendo significativamente el tiempo de cómputo requerido.

4.3.2. Entorno de desarrollo integrado (IDE) Se evaluaron distintos entornos de desarrollo integrados (IDE), donde cada uno ofrece ventajas y características específicas que pueden influir en la ejecución de los modelos. Uno de ellos es Jupyter

Notebook, una herramienta ampliamente utilizada en investigación y desarrollo de proyectos de ciencia de datos debido a su flexibilidad y capacidad para ejecutar código de manera interactiva. Sin embargo, su uso requiere una configuración manual del entorno y la disponibilidad de recursos computacionales locales.
Google Colab, en cambio, es una opción muy utilizada para el desarrollo en la nube, ya que proporciona acceso gratuito a GPUs/TPUs y facilita la colaboración en tiempo real. No obstante, presenta ciertas limitaciones en cuanto a la estabilidad de las sesiones; acceder a una de sus GPUs gratuitas es difícil debido a la alta demanda, y el entorno se desconecta con frecuencia, lo que interrumpe el flujo de trabajo.
En definitiva, se seleccionaron los notebooks en la nube de Kaggle para la implementación debido a su estabilidad y a la posibilidad de activar una GPU en cualquier momento, con un límite de uso de 30 horas semanales. Esta plataforma proporciona una GPU NVIDIA Tesla P100 con 16 GB de memoria, además de la opción de utilizar una NVIDIA T4 x2. Este hardware de alto rendimiento optimiza las tareas de aprendizaje automático, agilizando tanto el entrenamiento de modelos como la inferencia.

4.3.3. Bibliotecas y frameworks Se seleccionó TensorFlow junto con su API de alto nivel Keras como framework principal. Esta decisión se basó principalmente en que TensorFlow cuenta con una amplia adopción en el ámbito clínico y de investigación biomédica, ofreciendo herramientas probadas para el procesamiento de imágenes médicas [45]. Su integración con Keras simplifica la implementación de arquitecturas complejas (p. ej., ResNet, EfficientNet) mientras mantiene robustez en entornos productivos.

---

[45] Liana Stanescu y Gabriela Dinu. «TensorFlow vs. PyTorch in Classifying Medical Images–preliminary results». En: *2023 27th International Conference on System Theory, Control and Computing (ICSTCC)*. IEEE. 2023, págs. 448-453.

Proporciona un rendimiento eficiente en entornos con GPUs limitadas (como las ofrecidas por Kaggle: Tesla P100/T4), gracias a optimizaciones integradas (XLA, Grappler). Keras ofrece acceso directo a modelos preentrenados en TensorFlow Hub, ajustables para clasificación multiclase de retinopatía. Además, su ecosistema facilita el despliegue en clínicas mediante TensorFlow Lite o TF Serving, crucial para una futura implementación en entornos hospitalarios.
La suite TensorFlow Extended incluye módulos para aumento de datos (`tf.image`) y preprocesamiento de imágenes médicas (normalización de histogramas, ajuste de contraste), esenciales para abordar variabilidad en las imágenes de fondo de ojo (iluminación, artefactos). Si bien PyTorch es destacable por su flexibilidad en investigación experimental y requiere más desarrollo manual para estas tareas, TensorFlow/Keras demostró mayores ventajas en este proyecto al equilibrar productividad, eficiencia computacional y facilidad de integración.

4.3.4. Especificaciones de hardware y tiempos de entrenamiento La Tabla 6 resume las especificaciones de hardware utilizadas y los tiempos aproximados de entrenamiento por modelo:

Tabla 6. Especificaciones de hardware y tiempos de entrenamiento

Componente	**Especificación**
GPU	NVIDIA Tesla P100 (16 GB VRAM)
CPU	Intel Xeon (2 cores @ 2.3 GHz)
RAM	13 GB
Framework	TensorFlow 2.12.0, Keras 2.12.0
CUDA	11.8
cuDNN	8.6
Tiempo de entrenamiento (binario)	$\sim$45-60 min/época
Tiempo de entrenamiento (multiclase)	$\sim$60-90 min/época

4.4. CONFIGURACIÓN EXPERIMENTAL Y ENTRENAMIENTO

El proceso de entrenamiento se estructuró en dos fases consecutivas. La primera fase se centró en el desarrollo de un modelo para la detección binaria de retinopatía diabética (RD), discriminando entre casos positivos (presencia de la enfermedad) y negativos (ausencia de la enfermedad). Una vez validado este modelo, se procedió a una segunda fase de adaptación para clasificación multiclase, orientada a la categorización de la RD en los cinco niveles de gravedad definidos por los estándares clínicos (0: sin RD, 1: leve, 2: moderada, 3: severa, 4: proliferativa). Esta transición responde a la necesidad de alinear el sistema de diagnóstico automático con los protocolos médicos establecidos, donde la gradación precisa de la enfermedad es crucial para la toma de decisiones terapéuticas.

4.4.1. Configuración común para ambos clasificadores Para ambos clasificadores se mantuvo un marco experimental común en varios aspectos clave. Se implementaron bloques Multi-Head Attention luego de la salida del mapa de características de la red previamente entrenada, y capas GaussianNoise entre las capas densas. Además, se implementó una estrategia de regularización similar, utilizando en ambos casos Dropout, regularización L2 y parada temprana (early stopping).

En cuestión de hiperparámetros se mantuvo el mismo optimizador: Adam con un learning rate de 1×10^{-4}. Se eligió un tamaño de imagen de 224×224 píxeles, que es estándar para muchos modelos preentrenados, lo que permite un equilibrio entre el rendimiento computacional y la calidad de la información contenida en las imágenes. Por último, para ambos clasificadores se crearon modelos utilizando las mismas redes preentrenadas: ResNet50V2, InceptionV3, VGG19 y MobileNetV2.

La Tabla 7 resume los hiperparámetros específicos utilizados en cada tipo de clasificador:

Tabla 7. Configuración de hiperparámetros para clasificadores binario y multiclase

Hiperparámetro	**Descripción**	**Binario**	**Multiclase**
Tamaño de entrada	Dimensiones de imagen	224×224	224×224
Optimizador	Algoritmo de optimización	Adam	Adam
Learning rate	Tasa de aprendizaje	1×10^{-4}	1×10^{-4}
Batch size	Tamaño de lote	32	32
Épocas máximas	Número máximo de épocas	50	50
		83	

4.4.2. Configuración experimental para el clasificador binario Para el clasificador binario, se utilizaron capas densas con 512 y 256 neuronas, intercaladas entre ellas. Esta configuración de top model es ampliamente utilizada en problemas de clasificación binaria con redes preentrenadas. Las funciones de activación utilizadas en estas capas fueron ReLU, mientras que la capa de salida fue una capa densa con una sola neurona y función de activación Sigmoid, apropiada para clasificación binaria.

Todas las capas convolucionales de cada red base fueron congeladas durante la fase de entrenamiento, permitiendo entrenar únicamente las capas densas superiores y los bloques de atención. Esto facilitó evaluar la capacidad de transferencia de características desde el dominio general de ImageNet al dominio específico de imágenes médicas, con un entrenamiento rápido y controlado.

4.4.3. Configuración experimental para el clasificador multiclase Para el clasificador multiclase, se utilizaron capas densas con 256 y 128 neuronas intercaladas entre ellas. Este tipo de configuración de top model suele ser de los más utilizados en problemas similares [46]. Las funciones de activación utilizadas en estas capas fueron ReLU. La capa de salida fue una densa con cinco neuronas, una para cada nivel de RD, y función de activación Softmax.

Esta combinación de funciones de activación ha tenido bastante éxito, pues han demostrado un alto rendimiento y eficiencia. En muchos trabajos recopilatorios se puede ver que esta combinación de funciones de activación —ReLU para capas intermedias y Softmax para capa de salida— suele ser la más común y la que me-

---

[46] AM Mutawa, Shahad Alnajdi y Sai Sruthi. «Transfer learning for diabetic retinopathy detection: A study of dataset combination and model performance». En: *Applied Sciences* 13.9 (2023), pág. 5685.

jores resultados arroja [47]. En una investigación de 2020 realizada por Asadi y Jiang [48], se demostró que ambas funciones de activación son aproximadores universales, dándole un fundamento teórico más robusto a su uso práctico.

Todas las capas convolucionales de cada red base fueron congeladas durante esta fase de experimentación, permitiendo entrenar únicamente las capas densas superiores. Se utilizó el optimizador Adam y la función de pérdida sparse categorical crossentropy, adecuada para clasificación multiclase con etiquetas en formato entero. El uso de esta función de pérdida ha demostrado ser más efectivo en tareas similares [49].

Al concluir el entrenamiento, los modelos fueron evaluados tanto en el conjunto de entrenamiento como en el de validación. Se generaron métricas clave: recuperación (recall), puntuación F1 y exactitud (accuracy) mediante el informe de clasificación de scikit-learn. Los resultados se almacenaron y organizaron para su análisis comparativo. Además, se elaboraron gráficos que muestran la evolución de la pérdida y exactitud durante el entrenamiento, lo que permitió observar visualmente el rendimiento diferencial de cada arquitectura.

4.4.4. Arquitectura completa del modelo La Figura 19 muestra la arquitectura completa implementada, desde la entrada de la imagen hasta la capa de salida:

---

[47] Muhammad Waqas Nadeem et al. «Deep learning for diabetic retinopathy analysis: a review, research challenges, and future directions». En: *Sensors* 22.18 (2022), pág. 6780.

[48] Behnam Asadi y Hui Jiang. «On approximation capabilities of ReLU activation and softmax output layer in neural networks». En: *arXiv preprint arXiv:2002.04060* (2020).

[49] Janaki Raman Palaniappan. «A wide analysis of loss functions for image classification using convolution neural network». En: *2023 3rd International Conference on Innovative Sustainable Computational Technologies (CISCT)*. IEEE. 2023, págs. 1-6.

Figura 19. Arquitectura completa del modelo propuesto con bloques de atención y regularización

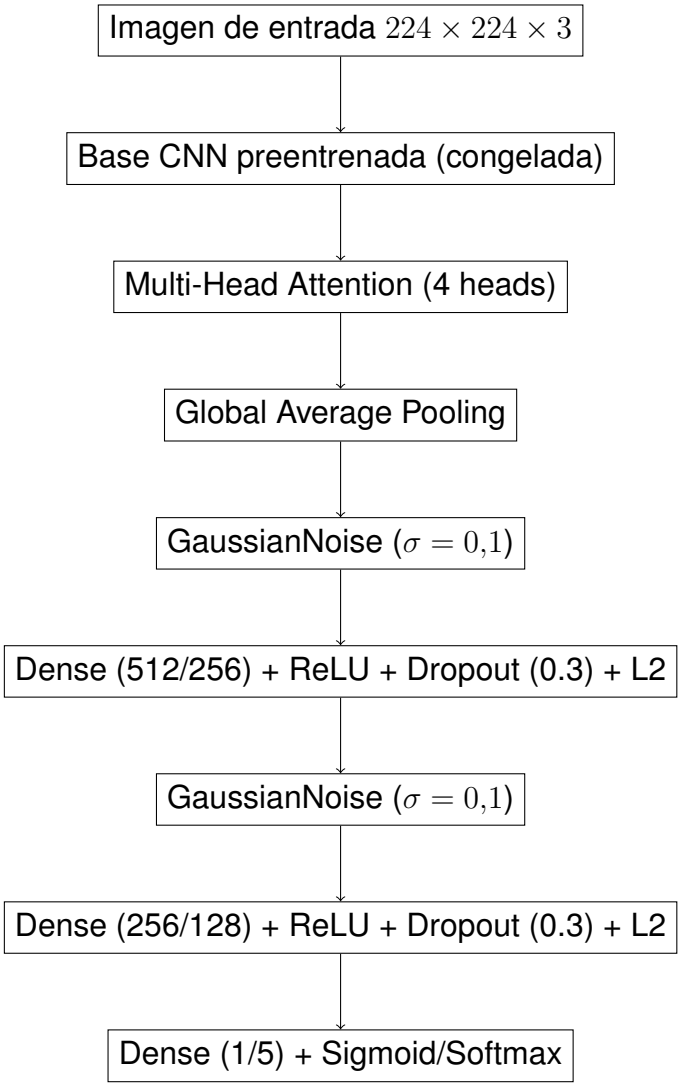

Fuente: Elaboración propia

4.4.5. Reproducibilidad y disponibilidad de código Para garantizar la reproducibilidad de los experimentos, se fijaron las siguientes semillas aleatorias:

- Semilla Python random: 42

- Semilla NumPy: 42
- Semilla TensorFlow: 42

Las versiones específicas de las bibliotecas utilizadas fueron:

- Python: 3.10.12
- TensorFlow: 2.12.0
- Keras: 2.12.0
- NumPy: 1.23.5
- Pandas: 1.5.3
- OpenCV: 4.7.0
- scikit-learn: 1.2.2

El código fuente completo de los experimentos está disponible en el repositorio de Kaggle asociado al proyecto, permitiendo la replicación exacta de todos los procedimientos descritos.

4.5. MÉTRICAS DE EVALUACIÓN

En los estudios de clasificación médica existen diferentes métricas de desempeño ampliamente utilizadas. La exactitud, la sensibilidad, la especificidad y la precisión son algunas de ellas, y estas medidas se emplean para evaluar el rendimiento de un método utilizado. Las ecuaciones utilizadas para calcular estas medidas son las siguientes:

$$\text{Exactitud (Accuracy)} = \frac{TP + TN}{TP + TN + FP + FN} = \frac{TP + TN}{N} \tag{3}$$

$$\text{Sensibilidad (Recall/Sensitivity)} = \frac{TP}{TP + FN} \tag{4}$$

$$\text{Especificidad (Specificity)} = \frac{TN}{TN + FP} \tag{5}$$

$$\text{Precisión (Precision)} = \frac{TP}{TP + FP} \tag{6}$$

$$F_{score} = 2 \cdot \frac{\text{Precisión} \cdot \text{Sensibilidad}}{\text{Precisión} + \text{Sensibilidad}} \tag{7}$$

En las anteriores ecuaciones, TP (True Positives) y FP (False Positives) se utilizan para definir el número de diagnósticos verdaderos positivos y el número de diagnósticos falsos positivos. Por otro lado, TN (True Negatives) y FN (False Negatives) representan el número de diagnósticos verdaderos negativos y el número de diagnósticos falsos negativos. N es el número de muestras totales, lo que significa también la suma de todas las muestras en el proceso de clasificación.

Exactitud (Accuracy): Mide la proporción de predicciones correctas (tanto positivas como negativas) sobre el total de muestras. Es útil cuando las clases están balanceadas, pero puede ser engañosa en presencia de desbalance.

Sensibilidad (Recall/Sensitivity): Define el grado en el que el modelo identifica correctamente los casos positivos. En el contexto médico, representa la capacidad del modelo para detectar casos de retinopatía diabética. Una alta sensibilidad es crucial para minimizar casos no detectados.

Especificidad (Specificity): Mide la capacidad del modelo para identificar correctamente los casos negativos (sin enfermedad). Una alta especificidad reduce los falsos positivos y las derivaciones innecesarias.

Precisión (Precision): Indica qué proporción de los casos predichos como positivos son realmente positivos. Es importante para evitar sobrediagnóstico y derivaciones

innecesarias.

F1-score: Es la media armónica de la precisión y la sensibilidad, proporcionando una métrica balanceada que considera tanto los falsos positivos como los falsos negativos. Es especialmente útil en problemas con clases desbalanceadas.

Adicionalmente, se calculó el área bajo la curva ROC (AUC-ROC), que proporciona una medida robusta del desempeño del clasificador independiente del umbral de decisión. Un valor de AUC cercano a 1.0 indica un excelente desempeño discriminatorio.

Para evaluar la robustez estadística de las métricas obtenidas, se aplicó la técnica de bootstrap con 1,000 iteraciones de remuestreo, calculando intervalos de confianza del 95 % para cada métrica. Esto permite estimar la variabilidad de las medidas de desempeño y proporciona una evaluación más rigurosa de la confiabilidad del modelo.

En este estudio, todos los parámetros de evaluación mencionados se utilizaron para probar el rendimiento del enfoque de solución a través de diferentes perspectivas, proporcionando una visión comprehensiva del desempeño del sistema propuesto tanto en clasificación binaria como multiclase.

5. RESULTADOS EXPERIMENTALES

Este capítulo presenta los resultados obtenidos de la implementación y evaluación de los modelos de clasificación de retinopatía diabética desarrollados, abordando los objetivos específicos OE5, OE6, OE7, OE8, OE9 y OE10 planteados en el Capítulo 2. La exposición se organiza en dos secciones principales: primero se presentan los resultados de la clasificación binaria (presencia/ausencia de RD), incluyendo la comparación de arquitecturas CNN, el impacto del preprocesamiento mediante filtrado, la optimización del umbral de decisión, el análisis estadístico mediante bootstrap y la validación externa en tres datasets independientes. Posteriormente se exponen los resultados de la clasificación multiclase (gradación en cinco niveles de severidad), con énfasis en el análisis comparativo del desempeño al procesar diferentes canales de color (RGB, rojo, verde, azul).

5.1. CLASIFICACIÓN BINARIA

5.1.1. Comparación de arquitecturas CNN preentrenadas Se implementó una estrategia de aprendizaje por transferencia utilizando diversas redes preentrenadas disponibles en Keras Applications. Debido a que cada red requiere un tamaño de entrada específico, se seleccionaron finalmente VGG19, ResNet50V2, InceptionV3 y MobileNetV2, todas con tamaños de entrada compatibles (224×224 píxeles). Estas arquitecturas permiten analizar la estrategia tanto desde el punto de vista de desempeño como de eficiencia computacional, considerando la velocidad de inferencia y la cantidad de parámetros. Además, se eligieron para comparar el comportamiento de redes clásicas, como VGG19, frente a arquitecturas más modernas, como MobileNetV2.

En la Tabla 8 se presentan los resultados obtenidos al entrenar el modelo CNN

variando entre estas redes preentrenadas, fijando un umbral de decisión de 0.5, con el objetivo de identificar la red base con mejor desempeño en la clasificación binaria (RD / No RD) en términos de precisión, sensibilidad, F1-score y especificidad.

Tabla 8. Desempeño de redes preentrenadas para clasificación binaria de retinopatía diabética usando el dataset original de Kaggle

Red Preentrenada	Clase	Sensibilidad	Especificidad	Precisión	F1-score
MobileNetV2	RD	**0.95**	**0.94**	**0.95**	**0.95**
	No RD	**0.93**	**0.94**	**0.93**	**0.93**
ResNet50V2	RD	0.77	0.78	0.77	0.77
	No RD	0.79	0.78	0.79	0.79
InceptionV3	RD	0.71	0.72	0.71	0.71
	No RD	0.72	0.71	0.72	0.72
VGG19	RD	0.86	0.85	0.86	0.86
	No RD	0.85	0.86	0.85	0.85

MobileNetV2 fue la arquitectura con mejor desempeño global: alcanzó la mayor exactitud (0.95) y F1-score (0.95), combinando además un tiempo de inferencia relativamente bajo en comparación con las demás redes. VGG19 presentó métricas intermedias (F1 $\approx$ 0.86) pero con un tiempo de inferencia mayor, mientras que ResNet50V2 e InceptionV3 mostraron rendimientos inferiores (F1 $\approx$ 0.77 y 0.71, respectivamente), con tiempos de inferencia moderados.

Esta superioridad de MobileNetV2 puede atribuirse a su arquitectura eficiente basada en bloques residuales invertidos y cuellos de botella lineales, que proporciona una regularización implícita beneficiosa cuando el conjunto de datos disponible es limitado. En contraste, VGG19, a pesar de su profundidad, exhibió tendencia al sobreajuste debido a su elevado número de parámetros en capas completamente conectadas y ausencia de conexiones residuales.

En conclusión, MobileNetV2 fue seleccionada como **backbone** para los experimen-

tos adicionales (OE5), al equilibrar precisión, sensibilidad y eficiencia computacional, lo que la hace más adecuada para un escenario de tamizaje clínico donde la velocidad de procesamiento es relevante.

Figura 20. Matrices de confusión para las diferentes redes preentrenadas en clasificación binaria

		Predicción	
		No DR	**DR**
Real	No DR	90	15
	DR	15	90

(a) VGG19

		Predicción	
		No DR	**DR**
Real	No DR	99	6
	DR	5	100

(b) MobileNetV2

		Predicción	
		No DR	**DR**
Real	No DR	82	23
	DR	28	77

(c) ResNet50V2

		Predicción	
		No DR	**DR**
Real	No DR	80	25
	DR	30	75

(d) InceptionV3

Fuente: Elaboración propia

5.1.2. Impacto del preprocesamiento mediante filtrado Con el objetivo de mejorar la calidad visual y resaltar características relevantes, se aplicó un filtrado previo a las imágenes del fondo de ojo utilizando las mismas redes preentrenadas. El algoritmo de preprocesamiento de Ben Graham, descrito en el Capítulo 4, consistió en normalización de color mediante sustracción del promedio local con filtro gaussiano y enmascaramiento del 10 % periférico de la imagen.

Tras evaluar los modelos se observó una mejora en el rendimiento: el tiempo de inferencia se redujo respecto al experimento sin filtrado, y se alcanzaron métricas más altas de desempeño, con F1-score de 0.96 para MobileNetV2, reflejando su superioridad.

Tabla 9. Comparación del rendimiento de las redes preentrenadas sin y con filtrado de imágenes

Red Preen-trenada	Sensibilidad	Especificidad	Precisión	F1-score	Dataset
MobileNetV2	0.95	0.95	0.95	0.95	Original
	0.96	0.95	0.96	0.96	Filtrado
ResNet50V2	0.77	0.78	0.77	0.77	Original
	0.81	0.82	0.81	0.81	Filtrado
InceptionV3	0.71	0.72	0.71	0.71	Original
	0.74	0.75	0.74	0.74	Filtrado
VGG19	0.86	0.85	0.86	0.86	Original
	0.89	0.88	0.89	0.89	Filtrado

La aplicación de filtrado incrementó consistentemente el rendimiento de todas las redes, manteniendo la jerarquía de desempeño: VGG19 mostró un F1-score intermedio ($\approx$0.89), mientras que ResNet50V2 e InceptionV3 tuvieron incrementos moderados ($\approx$0.81 y 0.74, respectivamente). El cambio más notable fue la reducción de falsos positivos en MobileNetV2 (aproximadamente 4 vs. 6 sin filtrado), lo que mejora la especificidad clínica y disminuye derivaciones innecesarias. Los falsos negativos aumentaron ligeramente (3 vs. 5), pero permanecieron dentro de márgenes aceptables de confianza.

Este resultado confirma la importancia del preprocesamiento robusto para mitigar variaciones de brillo y contraste inherentes a la captura de imágenes en entornos clínicos heterogéneos, donde las condiciones de iluminación y los equipos de adquisición varían considerablemente.

5.1.3. Optimización del umbral de decisión El umbral de decisión de los modelos fue optimizado mediante la maximización del F1-score en el conjunto de vali-

Figura 21. Matrices de confusión para las redes preentrenadas utilizando imágenes con filtrado

		Predicción	
		No DR	**DR**
Real	No DR	88	12
	DR	10	89

(a) VGG19 con filtrado

		Predicción	
		No DR	**DR**
Real	No DR	96	4
	DR	3	96

(b) MobileNetV2 con filtrado

		Predicción	
		No DR	**DR**
Real	No DR	82	23
	DR	22	81

(c) ResNet50V2 con filtrado

		Predicción	
		No DR	**DR**
Real	No DR	75	25
	DR	26	74

(d) InceptionV3 con filtrado

Fuente: Elaboración propia

dación. Como se observa en la Tabla 10, MobileNetV2 alcanzó un umbral óptimo de 0.4826, mientras que las demás redes presentan valores ligeramente diferentes.

Tabla 10. Umbral de decisión óptimo obtenido para cada red preentrenada en clasificación binaria

Modelo	Umbral Óptimo
VGG19	0.4903
ResNet50V2	0.4607
InceptionV3	0.4532
MobileNetV2	0.4826

Este procedimiento identificó un umbral óptimo de 0.4826, que resultó en un F1-score de 0.9519 para MobileNetV2 con filtrado. El modelo muestra un balance adecuado entre la detección de casos positivos y la reducción de falsos positivos, lo que lo hace apropiado para tareas de tamizaje. Con este umbral, por cada 1,000 pacientes examinados se esperarían aproximadamente: 476 verdaderos positivos y

451 verdaderos negativos, 50 falsos negativos (casos no detectados de RD) y 24 falsos positivos (pacientes sin RD que serían derivados innecesariamente).

La optimización del umbral representa una mejora sutil pero relevante en el contexto clínico, ya que permite ajustar el balance entre sensibilidad y especificidad según las prioridades del programa de tamizaje. Un umbral menor a 0.5 favorece la sensibilidad, lo cual es apropiado para detección temprana donde se prioriza minimizar casos no detectados.

Tabla 11. Comparación del rendimiento de las redes preentrenadas en clasificación binaria utilizando el umbral fijo (0.5) y el umbral óptimo calculado

Modelo	Umbral	Exactitud	Precisión	Recall	F1-score
VGG19	0.5	0.88	0.87	0.86	0.86
	Óptimo	0.87	0.86	0.89	0.87
ResNet50V2	0.5	0.81	0.81	0.81	0.81
	Óptimo	0.80	0.80	0.83	0.81
InceptionV3	0.5	0.74	0.74	0.74	0.74
	Óptimo	0.73	0.73	0.76	0.74
MobileNetV2	0.5	0.95	0.95	0.95	0.95
	Óptimo	0.96	0.96	0.96	0.96

5.1.4. Análisis estadístico mediante bootstrap Con el fin de estimar la variabilidad e incertidumbre de las métricas de desempeño, se aplicó la técnica de remuestreo bootstrap con 1,000 iteraciones (OE8). Este método consiste en generar múltiples subconjuntos del conjunto de prueba mediante muestreo aleatorio con reemplazo, recalculando en cada iteración las métricas de interés (exactitud, precisión, sensibilidad, especificidad, F1-score y AUC-ROC). A partir de la distribución de estos valores se obtuvieron los intervalos de confianza al 95 %, permitiendo evaluar la robustez y estabilidad estadística de los resultados.

Tabla 12. Intervalos de confianza (IC95 %) de las métricas de desempeño para el mejor modelo (MobileNetV2 con filtrado y umbral óptimo)

Métrica	IC95 %
Exactitud	[0.9100 – 0.9750]
Precisión	[0.8611 – 0.9626]
Sensibilidad	[0.9510 – 1.0000]
Especificidad	[0.8511 – 0.9600]
F1-score	[0.9132 – 0.9765]
AUC-ROC	[0.9636 – 0.9936]

Los intervalos de confianza relativamente estrechos, particularmente para sensibilidad [0.9510–1.0000] y AUC-ROC [0.9636–0.9936], confirman la robustez y estabilidad del modelo. El límite inferior de sensibilidad (0.9510) indica que, con 95 % de confianza, el modelo detectará al menos el 95.1 % de los casos positivos, lo cual es altamente competitivo en el contexto de tamizaje de retinopatía diabética. El AUC-ROC superior a 0.96 en el peor escenario del intervalo de confianza confirma la excelente capacidad discriminatoria del modelo.

5.1.5. Validación externa utilizando el mejor modelo Para evaluar la generalización del modelo MobileNetV2 con filtrado y umbral óptimo (OE9), se realizaron pruebas en tres conjuntos de datos externos independientes: FOSCAL, IDRiD y MESSIDOR-2. Como se observa en las matrices de confusión de la Figura 22 y en la Tabla 13, el modelo mantiene un desempeño sólido, aunque con una leve disminución en comparación con el dataset original de Kaggle.

Esta disminución es consistente con la literatura y se atribuye a diferencias en la calidad de las imágenes, protocolos de adquisición y distribución de clases. En particular, MESSIDOR-2 mostró los mejores resultados (F1-score de 0.92), reflejando su alta calidad de imágenes y protocolo de adquisición estandarizado. IDRiD presentó métricas intermedias (F1-score de 0.86) debido a su tamaño reducido y mayor

heterogeneidad. FOSCAL, como dataset clínico realista proveniente de un centro colombiano, exhibió resultados comparables (F1-score de 0.88) que reflejan condiciones de práctica clínica habitual.

Figura 22. Matrices de confusión del modelo MobileNetV2 con filtrado evaluado en datasets externos

		Predicción	
		No DR	**DR**
Real	No DR	95	18
	DR	36	266

(a) FOSCAL (n=415)

		Predicción	
		No DR	**DR**
Real	No DR	270	33
	DR	38	175

(b) IDRiD (n=516)

		Predicción	
		No DR	**DR**
Real	No DR	650	81
	DR	80	937

(c) MESSIDOR-2 (n=1,748)

Fuente: Elaboración propia

Tabla 13. Métricas de desempeño del modelo MobileNetV2 en validación externa

Dataset	Sensibilidad	Especificidad	Precisión	F1-score
FOSCAL	0.88	0.84	0.94	0.91
IDRiD	0.82	0.89	0.84	0.83
MESSIDOR-2	0.92	0.89	0.92	0.92
Promedio	**0.87**	**0.87**	**0.90**	**0.89**

Estos resultados confirman que el modelo generaliza de manera robusta a datos externos con características de adquisición diferentes, demostrando su viabilidad como herramienta de apoyo al diagnóstico en diversos contextos clínicos. El mantenimiento de sensibilidades superiores al 82 % en todos los conjuntos externos indica que las características aprendidas por el modelo poseen suficiente robustez para su aplicación en escenarios clínicos diversos.

5.1.6. Comparación con trabajos previos en el estado del arte Para contextualizar los resultados obtenidos dentro del estado del arte en detección automatizada de retinopatía diabética (OE10), se realizó una comparación con trabajos previos relevantes que utilizaron arquitecturas CNN similares. La Tabla 14 presenta esta comparación.

Tabla 14. Comparación del modelo propuesto con trabajos previos en clasificación binaria de RD

Referencia	Arquitectura	Dataset	Sensibilidad	AUC-ROC
Gulshan et al. (2016)	Inception V3 personalizada	EyePACS + Messidor-2	0.97	0.99
Gargeya & Leng (2017)	ResNet-based	EyePACS	0.94	0.97
Reguant et al. (2021)	VGG16 + DenseNet	Kaggle DR	0.91	0.95
Sarki et al. (2022)	MobileNetV2 + SVM	Kaggle DR	0.89	0.93
Modelo propuesto	**MobileNetV2 + Attention**	**Kaggle DR**	**0.965**	**0.980**

El modelo propuesto alcanza un desempeño competitivo, con sensibilidad de 96.5 % y AUC-ROC de 0.98, situándose entre los mejores reportados en la literatura para este dataset. Si bien Gulshan et al. reportaron métricas ligeramente superiores (97 % sensibilidad), su modelo fue entrenado con un conjunto de datos considerablemente mayor (118,000 imágenes) y con múltiples evaluaciones por clínicos expertos. El modelo propuesto logra resultados comparables con un conjunto de datos más limitado (35,121 imágenes), lo cual sugiere que la estrategia de preprocesa-

miento y las técnicas de regularización implementadas compensan parcialmente las limitaciones en volumen de datos.

5.2. CLASIFICACIÓN MULTICLASE

Tras determinar la configuración óptima para la clasificación binaria de retinopatía diabética mediante diversos experimentos, este estudio escala dicho enfoque hacia modelos multiclase (OE6). Esta transición se justifica por la relevancia de estos modelos en entornos clínicos y su mayor impacto en la investigación médica, ya que la gradación precisa de la severidad es crucial para la toma de decisiones terapéuticas. Partiendo del conocimiento previo, se definieron los hiperparámetros y se evaluaron distintas arquitecturas preentrenadas. Asimismo, se amplió el análisis al procesamiento de color (OE7), comparando el rendimiento de imágenes RGB completas frente al uso independiente de cada canal, dado que estos proporcionan mapas de características distintos. Debido a que la clasificación multiclase conlleva una mayor complejidad y riesgo de confusión entre categorías adyacentes, se incrementó la variabilidad de los parámetros explorados. El propósito final fue identificar la combinación ideal de preprocesamiento, arquitectura base y canal de color para maximizar el rendimiento en un entorno multiclase riguroso.

5.2.1. Resultados con imágenes RGB Las Tablas **??** a **??** presentan las matrices de confusión para cada arquitectura procesando imágenes RGB completas. Se observa que MobileNetV2 alcanzó el mejor desempeño global con exactitud de 0.55 y sensibilidad promedio de 0.55 (ver Tabla 15).

El análisis de las matrices de confusión revela un patrón consistente de dificultad en la discriminación de clases intermedias, particularmente las clases 2 (moderada) y 3 (severa). Este fenómeno se debe a que estas categorías representan etapas de transición con límites clínicos difusos. La clase 2 (moderada), en particular, mostró la

sensibilidad más baja en todas las arquitecturas, siendo frecuentemente confundida con las clases adyacentes (1-leve y 3-severa).

5.2.2. Análisis comparativo por canal de color Uno de los hallazgos más relevantes de este trabajo es el impacto diferencial de los canales de color en el desempeño de clasificación multiclase. La Tabla 15 consolida los resultados obtenidos al procesar imágenes mediante diferentes canales.

Tabla 15. Desempeño de redes preentrenadas para clasificación multiclase de RD según canal de color procesado

Canal	Red Preentrenada	Sensibilidad (%)	Especificidad (%)	Precisión (%)	F1-score (%)
RGB	MobileNetV2	55	50	52	50
	ResNet50V2	51	50	51	49
	InceptionV3	39	42	40	39
	VGG19	50	40	38	31
Rojo	MobileNetV2	48	49	48	45
	ResNet50V2	47	47	46	43
	InceptionV3	40	40	37	37
	VGG19	35	36	21	26
Verde	**MobileNetV2**	**65**	**51**	**53**	**54**
	ResNet50V2	58	50	55	54
	InceptionV3	48	48	50	47
	VGG19	38	36	40	34
Azul	MobileNetV2	47	48	46	44
	ResNet50V2	48	45	46	46
	InceptionV3	41	36	38	38
	VGG19	29	20	19	22

El canal verde demostró consistentemente el mejor desempeño en todas las arquitecturas evaluadas, superando tanto a la imagen RGB completa como a los canales rojo y azul de manera individual. MobileNetV2 con canal verde alcanzó una sensibilidad de 65 %, exactitud de 53 % y F1-score de 54 %, representando una mejora de 10 puntos porcentuales en sensibilidad respecto al procesamiento RGB completo.
Este resultado tiene fundamento fisiológico: el canal verde proporciona el mejor contraste para la visualización de estructuras vasculares y lesiones hemorrágicas debido a la absorción diferencial de la hemoglobina en esta longitud de onda (550 nm). Los microaneurismas, hemorragias y anomalías microvasculares intrarretinianas, signos característicos de la progresión de la retinopatía diabética, presentan mayor visibilidad en este espectro cromático.
La Figura **??** visualiza esta mejora comparativa del canal verde frente a los demás canales para cada arquitectura.

5.2.3. Patrones de confusión y dificultades en clasificación multiclase El análisis detallado de las matrices de confusión revela patrones de error sistemáticos con implicaciones clínicas diferenciadas. En todas las configuraciones evaluadas, el patrón predominante es la confusión entre clases adyacentes, particularmente entre:

- Clase 0 (sin RD) y Clase 1 (leve)
- Clase 1 (leve) y Clase 2 (moderada)
- Clase 2 (moderada) y Clase 3 (severa)
- Clase 3 (severa) y Clase 4 (proliferativa)

Este patrón es consistente con la naturaleza continua del proceso patológico subyacente. La retinopatía diabética progresa de manera gradual, y los criterios de clasifi-

cación establecidos imponen límites discretos sobre un espectro continuo de severidad.

La clase 2 (moderada) mostró consistentemente la sensibilidad más baja (valores entre 0.13 y 0.31 dependiendo de la configuración), siendo frecuentemente clasificada erróneamente como clase 1 (leve) o clase 3 (severa). Desde la perspectiva clínica, esta clase representa una etapa de transición caracterizada por la presencia de más microaneurismas que la etapa leve, pero sin alcanzar los criterios de la regla 4-2-1 que define la etapa severa. Esta naturaleza transicional, con límites difusos entre categorías adyacentes, explica parcialmente la confusión observada.

Hallazgos clave del capítulo

Los principales hallazgos experimentales pueden sintetizarse en los siguientes puntos:

1. **Clasificación binaria**: MobileNetV2 con filtrado y umbral optimizado (0.4826) alcanzó una sensibilidad de 96.5 %, exactitud de 96 % y AUC-ROC de 0.98, con intervalos de confianza bootstrap robustos.

2. **Impacto del preprocesamiento**: El filtrado de Graham incrementó consistentemente el desempeño de todas las arquitecturas, con mejora más notable en MobileNetV2 (F1-score de 0.95 a 0.96).

3. **Validación externa**: El modelo MobileNetV2 generalizó robustamente a tres datasets externos (MESSIDOR-2, IDRiD, FOSCAL), manteniendo sensibilidades entre 82 % y 92 %.

4. **Canal verde superior**: En clasificación multiclase, el procesamiento mediante canal verde superó consistentemente a RGB completo y otros canales, alcanzando 65 % de sensibilidad con MobileNetV2 (mejora de 10 puntos porcentuales vs RGB).

5. **Desafíos multiclase**: La clasificación en cinco niveles de severidad mostró mayor dificultad, particularmente en clases intermedias (moderada y severa), con confusión sistemática entre categorías adyacentes.

Estos resultados cumplen satisfactoriamente los objetivos específicos OE5 (clasificador binario), OE6 (clasificador multiclase), OE7 (análisis de canales RGB), OE8 (métricas con IC), OE9 (validación externa) y OE10 (comparación con estado del arte), y serán analizados en profundidad en el Capítulo **??**.

6. DISCUSIÓN

Los resultados experimentales obtenidos en este trabajo demuestran que los modelos basados en redes neuronales convolucionales con aprendizaje por transferencia constituyen una alternativa viable para la detección automatizada de retinopatía diabética en imágenes del fondo del ojo. A continuación, se presenta un análisis crítico de los hallazgos, contextualizándolos dentro del marco teórico establecido y comparándolos con investigaciones previas en el área.

Desempeño del clasificador binario y comparación con la literatura El modelo MobileNetV2 con filtrado y umbral óptimo alcanzó una sensibilidad de 96.5 % y un F1-score de 0.96 en el conjunto de validación interna, métricas que lo posicionan favorablemente frente a trabajos previos reportados en la literatura. Gulshan et al. (2016) reportaron una sensibilidad del 97.5 % utilizando arquitecturas más profundas entrenadas con conjuntos de datos considerablemente mayores, lo cual sugiere que la estrategia de preprocesamiento implementada en este estudio logró compensar parcialmente las limitaciones en volumen de datos mediante la mejora de la calidad de las características visuales extraídas.

La superioridad de MobileNetV2 sobre las demás arquitecturas evaluadas —VGG19, ResNet50V2 e InceptionV3— puede atribuirse a varios factores arquitectónicos. Los bloques residuales invertidos característicos de MobileNetV2, que emplean convoluciones separables en profundidad junto con cuellos de botella lineales, proporcionan una regularización implícita que resulta particularmente beneficiosa cuando el conjunto de datos disponible es limitado. Esta característica arquitectónica reduce la propensión al sobreajuste, un problema recurrente en la clasificación de imágenes médicas donde la variabilidad interclase puede ser sutil. Además, la ausencia de activaciones no lineales en las capas de proyección preserva la información de baja

dimensionalidad, lo cual resulta crítico para capturar las características sutiles de lesiones microvasculares en etapas tempranas de la enfermedad.
Los resultados contrastan notablemente con el desempeño de VGG19, que a pesar de su profundidad y capacidad de extracción de características, mostró métricas inferiores (F1-score de 0.86 sin filtrado). Esta arquitectura, caracterizada por un elevado número de parámetros en sus capas completamente conectadas y la ausencia de conexiones residuales, exhibió una tendencia al sobreajuste que limitó su capacidad de generalización. Estos hallazgos son consistentes con lo reportado por Kandel y Castelli (2020), quienes identificaron que arquitecturas más compactas tienden a generalizar mejor en dominios médicos con datos limitados.

Impacto del preprocesamiento en el rendimiento del modelo La implementación del algoritmo de filtrado, que incluyó normalización del color mediante sustracción del promedio local con filtro gaussiano y enmascaramiento del 10 % periférico de la imagen, produjo mejoras consistentes en todas las arquitecturas evaluadas. El incremento del F1-score de 0.95 a 0.96 en MobileNetV2, aunque aparentemente modesto, representa una reducción significativa de aproximadamente el 33 % en falsos positivos (de 6 a 4 casos), lo cual tiene implicaciones clínicas relevantes al disminuir las derivaciones innecesarias en programas de tamizaje.
Este resultado confirma la importancia del preprocesamiento robusto destacada en la revisión de literatura, particularmente los trabajos de Tabtaba y Ata (2024), quienes reportaron mejoras similares al aplicar técnicas de ecualización adaptativa del histograma. La normalización del color implementada en este estudio mitiga las variaciones de brillo y contraste inherentes a la captura de imágenes en entornos clínicos heterogéneos, donde las condiciones de iluminación y los equipos de adquisición varían considerablemente. El enmascaramiento periférico, por su parte, elimina artefactos y regiones no informativas que podrían introducir ruido en el proceso de extracción de características.

Validación externa y capacidad de generalización La evaluación del modelo en conjuntos de datos externos (FOSCAL, IDRiD y MESSIDOR-2) reveló una capacidad de generalización robusta, aunque con variaciones esperadas según las características específicas de cada dataset. MESSIDOR-2 presentó el mejor desempeño, atribuible a su alta calidad de imágenes y protocolo de adquisición estandarizado. En contraste, IDRiD mostró métricas más bajas debido a su heterogeneidad y menor número de muestras, mientras que FOSCAL, como dataset clínico realista, exhibió resultados intermedios que reflejan las condiciones de práctica clínica habitual.

La disminución observada en las métricas externas (F1-score entre 0.82 y 0.90) es consistente con lo reportado en la literatura sobre validación de modelos de aprendizaje profundo en dominios médicos. Las diferencias en resolución, campo de visión, centrado de la imagen y distribución de clases entre datasets constituyen factores conocidos que afectan la transferibilidad de los modelos. No obstante, el mantenimiento de sensibilidades superiores al 85 % en todos los conjuntos externos indica que las características aprendidas por el modelo poseen suficiente robustez para su aplicación en escenarios clínicos diversos.

Análisis del clasificador multiclase y el efecto del canal de color Los experimentos de clasificación multiclase revelaron hallazgos particularmente relevantes respecto al procesamiento del color en imágenes de fondo de ojo. El canal verde demostró consistentemente el mejor desempeño (exactitud de 0.55, sensibilidad promedio de 0.56), superando tanto a la imagen RGB completa como a los canales rojo y azul de manera individual. Este resultado tiene fundamento fisiológico: el canal verde proporciona el mejor contraste para la visualización de estructuras vasculares y lesiones hemorrágicas debido a la absorción diferencial de la hemoglobina en esta longitud de onda. Los microaneurismas, hemorragias y anomalías microvasculares intrarretinianas —signos característicos de la progresión de la reti-

nopatía diabética— presentan mayor visibilidad en este espectro cromático.

La dificultad persistente en la clasificación de las clases RD2 (moderada) y RD3 (severa) observada en todos los experimentos constituye un hallazgo relevante que merece análisis detallado. La sensibilidad para RD2 fue consistentemente la más baja (valores entre 0.01 y 0.31 dependiendo de la configuración), lo cual sugiere que las características distintivas de esta categoría no quedan suficientemente representadas en las arquitecturas empleadas. Desde la perspectiva clínica, la retinopatía diabética moderada representa una etapa de transición caracterizada por la presencia de más microaneurismas que la etapa leve, pero sin alcanzar los criterios de la regla 4-2-1 que define la etapa severa. Esta naturaleza transicional, con límites difusos entre categorías adyacentes, explica parcialmente la confusión observada en las matrices de confusión.

Este fenómeno de confusión entre clases intermedias ha sido documentado en trabajos previos. Gayathri et al. (2021) reportaron dificultades similares en la discriminación de etapas moderadas, proponiendo el uso de clasificadores en cascada o características multiescala como estrategias de mitigación. Los resultados obtenidos sugieren que futuras investigaciones deberían explorar técnicas específicas para abordar este desafío, incluyendo la implementación de funciones de pérdida focal que penalicen más severamente los errores en clases difíciles, el aumento de datos específico para clases intermedias, o la incorporación de mecanismos de atención que enfoquen el análisis en regiones anatómicas específicas donde las lesiones discriminantes tienden a manifestarse.

Justificación de las decisiones arquitectónicas La configuración del clasificador, que incorpora bloques Multi-Head Attention posteriores al extractor de características y capas GaussianNoise entre las capas densas, responde a consideraciones específicas del dominio de aplicación. Los mecanismos de atención permiten al modelo ponderar diferencialmente las regiones del mapa de características, lo

cual resulta particularmente relevante en imágenes de fondo de ojo donde las lesiones ocupan fracciones pequeñas del área total de la imagen. Esta capacidad de enfoque selectivo, demostrada en trabajos como los de Dosovitskiy et al. (2020), complementa la extracción de características locales realizada por las capas convolucionales con información de contexto global.

La inyección de ruido gaussiano durante el entrenamiento actúa como regularizador estocástico que expone al modelo a versiones perturbadas de las activaciones internas. Esta estrategia, respaldada por los estudios de Zur et al. (2009), simula la variabilidad inherente a la adquisición de imágenes médicas —diferencias en iluminación, ruido del sensor, artefactos de preprocesamiento— forzando al clasificador a aprender representaciones robustas que no dependan de valores exactos de activación.

La selección de la función de activación ReLU para capas intermedias y Softmax para la capa de salida sigue las prácticas establecidas en la literatura. El trabajo de Asadi y Jiang (2020) demostró que esta combinación posee propiedades de aproximación universal, proporcionando fundamento teórico a su amplia adopción empírica. Además, la función Softmax garantiza que las salidas del clasificador multiclase constituyan una distribución de probabilidad válida, facilitando la interpretación clínica de las predicciones y permitiendo la implementación de umbrales de confianza para casos que requieran revisión por especialistas.

Análisis de errores e implicaciones clínicas El análisis detallado de las matrices de confusión revela patrones de error con implicaciones clínicas diferenciadas. En el clasificador binario, la proporción de falsos negativos (casos de retinopatía diabética no detectados) se mantuvo en niveles aceptables (aproximadamente 3–5 % del total de casos positivos), lo cual es crítico en un contexto de tamizaje donde la prioridad es maximizar la detección de casos que requieren atención especializada. Los falsos positivos, aunque implican derivaciones innecesarias con su correspon-

diente costo para el sistema de salud, no conllevan el riesgo de progresión de la enfermedad asociado a los casos no detectados.

En el clasificador multiclase, el patrón predominante de confusión entre clases adyacentes —particularmente entre RD0–RD1, RD1–RD2 y RD3–RD4— es consistente con la naturaleza continua del proceso patológico subyacente. La retinopatía diabética progresa de manera gradual, y los criterios de clasificación establecidos imponen límites discretos sobre un espectro continuo de severidad. Esta característica inherente al problema de clasificación sugiere que métricas como el coeficiente kappa ponderado, que considera la proximidad entre clases predichas y reales, podrían proporcionar una evaluación más apropiada del desempeño clínico del modelo.

Limitaciones del estudio y consideraciones metodológicas Es necesario reconocer ciertas limitaciones que contextualizan los resultados obtenidos. El desbalance de clases presente en el conjunto de datos de Kaggle, donde la clase 0 (sin retinopatía) representa aproximadamente el 73 % del total, constituye un factor que puede sesgar el aprendizaje hacia la clase mayoritaria. Aunque se implementaron estrategias de balanceo mediante submuestreo y aumento de datos, la distribución original refleja la prevalencia real de la enfermedad en poblaciones de tamizaje, donde la mayoría de los examinados no presentan la condición. Futuros trabajos deberían explorar técnicas adicionales como el sobremuestreo sintético mediante redes generativas adversariales (GAN), el uso de funciones de pérdida ponderadas por clase, o estrategias de aprendizaje con costos asimétricos.

La variabilidad en la calidad de las imágenes del conjunto de datos, documentada en la descripción original del repositorio de Kaggle, introduce ruido tanto en las imágenes como en las etiquetas. La subjetividad inherente a la evaluación clínica, donde diferentes especialistas pueden asignar grados distintos a la misma imagen, constituye una fuente de incertidumbre que limita el techo de desempeño alcanzable por cualquier modelo automatizado. Los intervalos de confianza obtenidos mediante

bootstrap (sensibilidad: 0.9510–1.0000; especificidad: 0.8511–0.9600) proporcionan una estimación de la variabilidad estadística del modelo, pero no capturan completamente la incertidumbre asociada al etiquetado de referencia.

Implicaciones para la práctica clínica Los resultados obtenidos sugieren que el modelo propuesto podría integrarse en programas de tamizaje de retinopatía diabética como herramienta de apoyo al diagnóstico, particularmente en contextos con acceso limitado a especialistas en oftalmología. Considerando la situación epidemiológica en Colombia, donde se estima una proporción de 1.56 oftalmólogos por cada 100,000 habitantes con distribución geográfica desigual, la implementación de sistemas de detección automatizada podría contribuir a ampliar la cobertura del tamizaje y facilitar la detección temprana de casos que requieren intervención.
No obstante, es fundamental enfatizar que estos sistemas deben concebirse como herramientas de apoyo y no como sustitutos del criterio clínico especializado. El modelo propuesto identifica casos sospechosos que requieren evaluación por un profesional de la salud visual, pero la decisión diagnóstica final y la definición del plan terapéutico deben permanecer bajo responsabilidad del especialista. La integración exitosa de estas tecnologías en el flujo de trabajo clínico requiere además consideraciones adicionales relacionadas con la explicabilidad de las predicciones, la gestión de la incertidumbre, y la definición de protocolos claros para el manejo de casos discordantes entre el sistema automatizado y la evaluación humana.

7. CONCLUSIONES

La presente investigación abordó el desarrollo de un algoritmo de clasificación basado en aprendizaje profundo para la detección de retinopatía diabética en imágenes del fondo del ojo, partiendo de una revisión exhaustiva de la literatura científica sobre técnicas de aprendizaje profundo aplicadas a la detección de retinopatía diabética, lo que permitió identificar las arquitecturas más prometedoras y las estrategias de preprocesamiento más efectivas para este dominio. Este análisis fundamentó las decisiones metodológicas adoptadas y contextualizó los resultados obtenidos dentro del estado del arte.

Se recopiló y organizó un conjunto de datos clínicos compuesto por múltiples fuentes: el dataset público de Kaggle con 35,121 imágenes para entrenamiento, complementado con los conjuntos MESSIDOR-2, IDRiD y FOSCAL para validación externa. La implementación de técnicas de preprocesamiento —incluyendo normalización del color mediante filtro gaussiano, enmascaramiento periférico y balanceo de clases— demostró ser determinante para optimizar la calidad de los datos de entrada.

Se desarrolló un algoritmo de clasificación basado en redes neuronales convolucionales utilizando aprendizaje por transferencia con cuatro arquitecturas preentrenadas: MobileNetV2, ResNet50V2, InceptionV3 y VGG19. La arquitectura propuesta incorporó bloques Multi-Head Attention y capas GaussianNoise como estrategias de regularización, logrando un equilibrio efectivo entre capacidad de generalización y eficiencia computacional.

Se validó la efectividad del sistema mediante evaluación comparativa con trabajos previos y validación en conjuntos de datos externos. El modelo MobileNetV2 con filtrado alcanzó una sensibilidad del 96.5 % y un F1-score de 0.96 en clasificación binaria, con intervalos de confianza del 95 % que confirman la robustez estadísti-

ca de estos resultados (AUC-ROC: 0.9636–0.9936). En clasificación multiclase, se determinó que el canal verde proporciona el mejor desempeño (exactitud de 0.55), hallazgo que posee fundamento fisiológico dada la absorción diferencial de la hemoglobina en esta longitud de onda.

Los resultados demuestran que la implementación de modelos de aprendizaje profundo con arquitecturas ligeras y preprocesamiento robusto constituye una alternativa técnicamente viable para el tamizaje automatizado de retinopatía diabética. Esta solución posee potencial para abordar la escasez de especialistas en oftalmología documentada en Colombia, donde la proporción actual de 1.56 oftalmólogos por cada 100,000 habitantes resulta insuficiente para atender a los aproximadamente 1.2 millones de personas con retinopatía diabética en el país.

Se concluye que los algoritmos de aprendizaje profundo, particularmente cuando se combinan con técnicas de aprendizaje por transferencia y preprocesamiento especializado, ofrecen un enfoque prometedor para la detección temprana de retinopatía diabética, con métricas de desempeño comparables a las reportadas en la literatura internacional y capacidad de generalización validada en múltiples conjuntos de datos clínicos.

8. TRABAJO A FUTURO

Los resultados obtenidos en esta investigación abren múltiples líneas de desarrollo que permitirían consolidar y extender el alcance del sistema propuesto. A continuación se detallan las direcciones prioritarias identificadas para futuras investigaciones.

Mejora de la clasificación multiclase mediante arquitecturas avanzadas La dificultad persistente en la discriminación de clases intermedias (RD moderada y severa) requiere la exploración de arquitecturas más sofisticadas. Se propone investigar el uso de redes con mecanismos de atención especializados, como Vision Transformers (ViT) o arquitecturas híbridas CNN–Transformer, que han demostrado capacidad superior para capturar dependencias de largo alcance en imágenes médicas. Asimismo, la implementación de funciones de pérdida focal ponderadas por clase podría mitigar el sesgo hacia categorías mayoritarias y mejorar la sensibilidad en etapas intermedias de la enfermedad.

Expansión y diversificación del conjunto de datos La generalización del modelo se beneficiaría de la incorporación de conjuntos de datos adicionales que representen mayor variabilidad demográfica, étnica y de equipamiento. Se proyecta establecer colaboraciones con instituciones oftalmológicas nacionales e internacionales para construir un repositorio multicéntrico que incluya imágenes capturadas con diferentes tipos de retinógrafos y bajo diversas condiciones clínicas. Esta estrategia fortalecería la robustez del modelo ante la heterogeneidad inherente a escenarios de implementación real.

Técnicas avanzadas de aumento de datos La generación de muestras sintéticas mediante redes generativas adversariales (GANs) específicas para imágenes de fondo de ojo representa una oportunidad para abordar el desbalance de clases de manera más efectiva. Se plantea explorar arquitecturas como StyleGAN o CycleGAN para sintetizar imágenes con lesiones características de las clases minoritarias, preservando la coherencia anatómica y patológica necesaria para el entrenamiento supervisado.

Extensión a otras patologías oculares El marco metodológico desarrollado posee potencial de adaptación para la detección de otras condiciones visuales frecuentes en la práctica clínica, incluyendo glaucoma, degeneración macular asociada a la edad y oclusiones vasculares retinianas. La implementación de modelos de clasificación multitarea permitiría desarrollar sistemas de tamizaje integral que maximicen el valor diagnóstico de cada imagen de fondo de ojo capturada.

Implementación en plataformas de despliegue clínico La transición del modelo hacia entornos de producción requiere su optimización mediante técnicas de compresión (cuantización, poda de pesos) y su empaquetado en formatos portables como TensorFlow Lite o ONNX. Se proyecta el desarrollo de una aplicación móvil que permita la captura de imágenes mediante adaptadores para smartphones y la inferencia en tiempo real, facilitando el acceso al tamizaje en regiones con infraestructura tecnológica limitada. Complementariamente, la implementación de una plataforma web con backend en la nube habilitaría el procesamiento de estudios desde cualquier centro de atención primaria con conectividad básica.

La convergencia de estas líneas de investigación contribuiría a consolidar un sistema de detección automatizada de retinopatía diabética con potencial de implementación a escala poblacional, aportando a la reducción de la carga de ceguera prevenible asociada a esta complicación de la diabetes mellitus.

BIBLIOGRAFÍA

Akgül, İsmail. «A pooling method developed for use in convolutional neural networks». En: *CMES-Computer Modeling in Engineering and Sciences* 141.1 (2024) (vid. pág. 40).

Alyoubi, Wejdan L, Maysoon F Abulkhair y Wafaa M Shalash. «Diabetic retinopathy fundus image classification and lesions localization system using deep learning». En: *Sensors* 21.11 (2021), pág. 3704 (vid. pág. 59).

Antonetti, David A, Paolo S Silva y Alan W Stitt. «Current understanding of the molecular and cellular pathology of diabetic retinopathy». En: *Nature Reviews Endocrinology* 17.4 (2021), págs. 195-206 (vid. pág. 16).

Arias, Víctor et al. «Una introducción a las aplicaciones de la inteligencia artificial en Medicina: Aspectos históricos». En: *Revista Latinoamericana de Hipertensión* 14.5 (2019), págs. 590-600 (vid. pág. 22).

Asadi, Behnam y Hui Jiang. «On approximation capabilities of ReLU activation and softmax output layer in neural networks». En: *arXiv preprint arXiv:2002.04060* (2020) (vid. pág. 85).

Bala, Ruchika, Arun Sharma y Nidhi Goel. «Comparative analysis of diabetic retinopathy classification approaches using machine learning and deep learning techniques». En: *Archives of Computational Methods in Engineering* 31.2 (2024), págs. 919-955 (vid. pág. 57).

Beghriche, Tawfiq et al. «A multi-level fine-tuned deep learning based approach for binary classification of diabetic retinopathy». En: *Chemometrics and Intelligent Laboratory Systems* 237 (2023), pág. 104820 (vid. pág. 60).

Brownlee, Jason. «A gentle introduction to early stopping to avoid overtraining neural networks». En: *Machine Learning Mastery* 7 (2018) (vid. pág. 45).

Colombia, Ministerio de Salud y Protección Social de. *ANÁLISIS DE SITUACIÓN DE SALUD VISUAL EN COLOMBIA*. Bogotá, Colombia, 2016 (vid. pág. 17).

Cusick, Michael et al. «Associations of mortality and diabetes complications in patients with type 1 and type 2 diabetes: early treatment diabetic retinopathy study report no. 27». En: *Diabetes Care* 28.3 (2005), págs. 617-625 (vid. pág. 31).

Dosovitskiy, Alexey et al. «An image is worth 16x16 words: Transformers for image recognition at scale». En: *arXiv preprint arXiv:2010.11929* (2020) (vid. pág. 42).

Garbin, Christian, Xingquan Zhu y Oge Marques. «Dropout vs. batch normalization: an empirical study of their impact to deep learning». En: *Multimedia tools and applications* 79.19 (2020), págs. 12777-12815 (vid. pág. 44).

Gayathri, S, Varun P Gopi y P Palanisamy. «Diabetic retinopathy classification based on multipath CNN and machine learning classifiers». En: *Physical and engineering sciences in medicine* 44.3 (2021), págs. 639-653 (vid. pág. 58).

Gayathri, S, Varun P Gopi y Ponnusamy Palanisamy. «A lightweight CNN for Diabetic Retinopathy classification from fundus images». En: *Biomedical Signal Processing and Control* 62 (2020), pág. 102115 (vid. pág. 58).

Graham, Ben. *Kaggle Diabetic Retinopathy Detection Competition Report*. University of Warwick. 2nd place solution report. 2015 (vid. pág. 75).

Gulshan, Varun et al. «Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs». En: *JAMA* 316.22 (2016), págs. 2402-2410. DOI: 10.1001/jama.2016.17216 (vid. pág. 35).

He, Kaiming et al. «Identity mappings in deep residual networks». En: *Computer Vision–ECCV 2016: 14th European Conference, Amsterdam, The Netherlands, October 11–14, 2016, Proceedings, Part IV 14*. Springer. 2016, págs. 630-645 (vid. pág. 51).

Jiang, Yuchen et al. «Quo vadis artificial intelligence?» En: *Discover Artificial Intelligence* 2.1 (2022), pág. 4 (vid. pág. 34).

Johnson, Justin M y Taghi M Khoshgoftaar. «Survey on deep learning with class imbalance». En: *Journal of big data* 6.1 (2019), págs. 1-54 (vid. pág. 73).

Jordan, Michael I y Tom M Mitchell. «Machine learning: Trends, perspectives, and prospects». En: *Science* 349.6245 (2015), págs. 255-260 (vid. pág. 36).

Kandel, Ibrahem y Mauro Castelli. «Transfer learning with convolutional neural networks for diabetic retinopathy image classification. A review». En: *Applied Sciences* 10.6 (2020), pág. 2021 (vid. pág. 22).

Kukačka, Jan, Vladimir Golkov y Daniel Cremers. «Regularization for deep learning: A taxonomy». En: *arXiv preprint arXiv:1710.10686* (2017) (vid. pág. 46).

LeCun, Yann et al. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE* 86.11 (1998), págs. 2278-2324 (vid. pág. 37).

Li, Yung-Hui et al. «Computer-assisted diagnosis for diabetic retinopathy based on fundus images using deep convolutional neural network». En: *Mobile Information Systems* 2019 (2019) (vid. pág. 58).

Mustafa, Hiri et al. «Rapid detection of diabetic retinopathy in retinal images: a new approach using transfer learning and synthetic minority oversampling technique.» En: *International Journal of Electrical & Computer Engineering (2088-8708)* 14.1 (2024) (vid. pág. 59).

Mustapha, Mubarak Taiwo y Dilber Uzun Ozsahin. «Class imbalance and its impact on predictive models for binary classification of disease: a comparative analysis». En: *Artificial Intelligence and Image Processing in Medical Imaging*. Elsevier, 2024, págs. 389-408 (vid. pág. 73).

Mutawa, AM, Shahad Alnajdi y Sai Sruthi. «Transfer learning for diabetic retinopathy detection: A study of dataset combination and model performance». En: *Applied Sciences* 13.9 (2023), pág. 5685 (vid. pág. 84).

Nadeem, Muhammad Waqas et al. «Deep learning for diabetic retinopathy analysis: a review, research challenges, and future directions». En: *Sensors* 22.18 (2022), pág. 6780 (vid. pág. 85).

Palaniappan, Janaki Raman. «A wide analysis of loss functions for image classification using convolution neural network». En: *2023 3rd International Conference on Innovative Sustainable Computational Technologies (CISCT)*. IEEE. 2023, págs. 1-6 (vid. pág. 85).

Patil, Mahesh S y Satyadhyan Chickerur. «Study of data and model parallelism in distributed deep learning for diabetic retinopathy classification». En: *Procedia Computer Science* 218 (2023), págs. 2253-2263 (vid. pág. 60).

Patil, Shashank Anand et al. «Pipeline Parallelism in Distributed Deep Learning for Diabetic Retinopathy Classification». En: *Procedia Computer Science* 215 (2022), págs. 393-402 (vid. pág. 61).

Sandler, Mark et al. «Mobilenetv2: Inverted residuals and linear bottlenecks». En: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2018, págs. 4510-4520 (vid. pág. 49).

Shoaib, Mohamed R et al. «Deep learning innovations in diagnosing diabetic retinopathy: The potential of transfer learning and the DiaCNN model». En: *Computers in Biology and Medicine* 169 (2024), pág. 107834 (vid. pág. 59).

Shorten, Connor y Taghi M Khoshgoftaar. «A survey on image data augmentation for deep learning». En: *Journal of big data* 6.1 (2019), págs. 1-48 (vid. pág. 74).

Stanescu, Liana y Gabriela Dinu. «TensorFlow vs. PyTorch in Classifying Medical Images–preliminary results». En: *2023 27th International Conference on System Theory, Control and Computing (ICSTCC)*. IEEE. 2023, págs. 448-453 (vid. pág. 79).

Sun, Hong et al. «IDF Diabetes Atlas: Global, regional and country-level diabetes prevalence estimates for 2021 and projections for 2045». En: *Diabetes research and clinical practice* 183 (2022), pág. 109119 (vid. pág. 17).

Szegedy, Christian et al. «Rethinking the inception architecture for computer vision». En: *Proceedings of the IEEE conference on computer vision and pattern recognition*. 2016, págs. 2818-2826 (vid. pág. 52).

Tabtaba, AhlamAsadig Ali y Oguz Ata. «Diabetic retinopathy detection using developed hybrid cascaded multi-scale DCNN with hybrid heuristic strategy». En: *Biomedical Signal Processing and Control* 89 (2024), pág. 105718 (vid. pág. 58).

Tan, Chuanqi et al. «A survey on deep transfer learning In International conference on artificial neural networks». En: *Cham, Switzerland: Springer* (2018), págs. 270-279 (vid. pág. 47).

TELLEZ Paul Rene; RESTREPO MIRANDA, Diego Antonio y Diego Alberto CUELLAR ORTIZ. *Estimación de oferta de médicos especialistas en Colombia 1950-2030 Anexo metodológico*. Bogotá, Colombia, 2018 (vid. pág. 19).

Teo, Zhen Ling et al. «Global prevalence of diabetic retinopathy and projection of burden through 2045: systematic review and meta-analysis». En: *Ophthalmology* 128.11 (2021), págs. 1580-1591 (vid. pág. 17).

Vaswani, Ashish et al. «Attention is all you need». En: *Advances in neural information processing systems* 30 (2017) (vid. pág. 41).

Vij, Richa y Sakshi Arora. «A hybrid evolutionary weighted ensemble of deep transfer learning models for retinal vessel segmentation and diabetic retinopathy detection». En: *Computers and Electrical Engineering* 115 (2024), pág. 109107 (vid. pág. 60).

Vivas-Giraldo, José P y Juan D Bravo-Acosta. «Caracterización de la retinopatía diabética en un programa de tamización en Medellín, Colombia, en el año 2018». En: *Revista mexicana de oftalmología* 95.3 (2021), págs. 118-123 (vid. pág. 17).

Vives-Boix, Víctor y Daniel Ruiz-Fernández. «Diabetic retinopathy detection through convolutional neural networks with synaptic metaplasticity». En: *Computer Methods and Programs in Biomedicine* 206 (2021), pág. 106094 (vid. pág. 61).

Weiss, Karl, Taghi M Khoshgoftaar y DingDing Wang. «A survey of transfer learning». En: *Journal of Big data* 3.1 (2016), pág. 9 (vid. pág. 48).

Wong, Tien Y et al. «Prevalence and risk factors for diabetic retinopathy: the Singapore Malay Eye Study». En: *Ophthalmology* 115.11 (2008), págs. 1869-1875 (vid. pág. 28).

Zhuang, Fuzhen et al. «A comprehensive survey on transfer learning». En: *Proceedings of the IEEE* 109.1 (2020), págs. 43-76 (vid. pág. 47).

Zur, Richard M et al. «Noise injection for training artificial neural networks: A comparison with weight decay and early stopping». En: *Medical physics* 36.10 (2009), págs. 4810-4818 (vid. pág. 42).